

國立東華大學資訊工程學系

碩士論文

指導教授：李官陵 博士

**基於 EfficientNet 與 Swin Transformer
交叉注意力特徵融合之胸腔 X 光多標籤
分類**

*Multi-label Chest X-ray Classification Based on Cross-Attention Feature
Fusion of EfficientNet and Swin Transformer*



研究生：黃予希 撰

中華民國一一五年七月

學位考試委員會審定書

Certificate of Approval of Examination Committee

國立東華大學 資訊工程學系資工組

研究生 黃予希 君所提之 論文

National Dong Hwa University
The Thesis Graduate Student Proposed

(題目) 基於EfficientNet與Swin Transformer 交叉注意力特徵融合之胸
Title Multi-label Chest X-ray Classification Based on Cross-Attention Feature Fusion of EfficientNet and Swin Transformer

經本委員會審查並舉行口試，認為符合 碩士 學位標準。

After evaluation and the oral examination by the committee members, the student complies with the master degree

學位考試委員會召集人

The Convener of Examination Committee

委員

Committee Member

委員

Committee Member

委員

Committee Member

指導教授

Advising Professor

系主任

(所長)

The Director of Department

中華民國

ROC

115 年

Year

6 月

Month

30 日

Date

國立東華大學
NATIONAL DONG HWA UNIVERSITY

學位論文原創性聲明書
DECLARATION OF THESIS/DISSERTATION ORIGINALITY

學位論文題目：基於 EfficientNet 與 Swin Transformer 交叉注意力特徵融合之胸腔 X 光多
標籤分類

Thesis/Dissertation Title : Multi-label Chest X-ray Classification Based on Cross-Attention
Feature Fusion of EfficientNet and Swin Transformer

本人在此聲明，所呈交的學位論文是在指導教授李官陵的指導下，由個人獨立研究所完成之最終版本。本人對論文內容負責，除了文中已經標註引用處的內容外，論文不包含任何其他人已經發表或撰寫過的研究成果。對本研究及學位論文做出重要貢獻的個人和組織，均已在文中以明確方式標明。

該論文內容如有違反學術道德或學術規範的行為，如造假、變造、抄襲、研究成果重複發表或未適當引註、以違法或不當手段影響論文審查、不當作者列名等，本人願意承擔由此而產生的法律責任和法律後果。

I declare that the thesis/dissertation herein is the final version of my work, which is composed and accomplished individually under the guidance of my supervisor, Prof. Guan-Ling Lee. I am responsible for the contents of this thesis/dissertation: It contains no research result that was previously published or written by another person. Information derived from published and unpublished work of others has been acknowledged in the text, and a list of references is given. Any contribution made by other individual or organization is explicitly acknowledged in the thesis/dissertation.

If any research misconduct, including fabrication, falsification, or plagiarism in proposing, performing, or reviewing research, or in reporting research results, is discovered in my thesis/dissertation, I am willing to bear corresponding legal responsibilities and all the results therefrom.

聲明人 Declarant: 黃予承
日期 Date: 2026/07/22 (yyyy/mm/dd)

謝辭

研究所階段的學習與研究歷程即將告一段落，回顧這段時間，從研究方向的摸索、實驗設計的調整，到論文撰寫與修改的過程，期間充滿挑戰與壓力，但也在不斷嘗試與堅持中完成了這份研究成果。能夠順利完成本篇論文。

首先，感謝李官陵指導教授在研究期間給予的指導與建議，無論是研究方向的規劃、實驗方法的建立，或是論文內容的修正，皆提供許多寶貴的意見，使本研究得以逐步完善。老師於研究過程中不僅提供專業的指導，也能理解學生於研究階段所面臨的挑戰，並給予充分的討論與交流空間，使研究過程能夠更加順利進行。

同時，也感謝羅壽之與彭勝龍口試委員於論文審查與口試過程中提供專業的建議與指正，使本論文能夠更加嚴謹與完整。

感謝研究所期間一同學習和玩樂的同學與朋友們，並於面對困難時給予支持與鼓勵，使這段求學歷程更加充實。特別感謝潘東瑋在研究過程中提供寶貴的經驗分享與建議，協助我釐清實驗執行時遇到的問題，使研究流程更加順暢，並大幅提升研究進行的效率。

最後，感謝家人在求學期間始終給予支持與陪伴。特別感謝爸爸在研究所期間多次前來花蓮給予鼓勵與陪伴，並提供穩定的經濟支持，使我能無後顧之憂地投入研究與完成學業。也感謝女朋友在研究期間始終陪伴在身旁，於研究壓力與論文撰寫過程中給予理解與鼓勵。

這段求學歷程能夠順利完成，除了自身的努力與堅持，更凝聚了師長、同儕與家人給予的支持與鼓勵。

研究生 黃予希 謹致於

國立東華大學 資訊工程學系碩士班

中華民國 一一五年七月

摘要

胸腔 X 光為臨床診斷的重要輔助工具，近年來深度學習技術也逐漸應用於醫學影像分析與輔助診斷領域。然而，深度學習模型在胸腔 X 光多標籤分類任務中，常面臨極端資料不平衡與單一模型能力受限等挑戰，導致模型對於罕見疾病的辨識度較低。為改善此問題，本研究採用 NIH ChestX-ray14 資料集進行深入探討。首先於資料前處理階段，測試不同程度之上採樣策略，實驗結果證實結合微幅影像增強與適度資料上採樣能提升分類效能，但過度上採樣則容易造成過擬合。

在架構設計方面，本研究探討二階段分類架構之成效，但發現該架構容易受到第一階段二分類模型誤判的影響，使錯誤傳遞至第二階段階段，導致整體效能不增反減。為突破單一模型與二階段分類架構之限制，本研究提出一套基於 EfficientNet 與 Swin Transformer 之交叉注意力特徵融合架構，利用 CNN 與 Transformer 的特性，兩者模型透過交叉注意力機制融合局部與全局特徵，並加入殘差連接與位置嵌入以穩定特徵傳遞並保留空間資訊，最後透過動態權重學習調整不同特徵的權重。實驗結果顯示，本融合架構在 F1-score (0.3930) 與 AUC (0.8449) 等指標上皆優於單一模型與二階段分類架構，展現其在胸腔 X 光疾病分類任務中的應用潛力。

關鍵字：胸腔 X 光、多標籤分類、資料不平衡、交叉注意力機制、EfficientNet、SwinTransformer

ABSTRACT

Chest X-rays are an important tool for clinical diagnosis, and deep learning has been widely applied to medical image analysis. However, multi-label chest X-ray classification often suffers from severe class imbalance and limited single-model capacity, resulting in poor performance on rare diseases. This study uses the NIH ChestX-ray14 dataset to investigate these issues.

In preprocessing, different oversampling strategies are tested. Results show that mild data augmentation combined with moderate oversampling improves performance, while excessive oversampling leads to overfitting.

A two-stage classification framework is also evaluated, but error propagation from the first-stage binary classifier negatively affects overall performance.

To address these limitations, this study proposes a cross-attention fusion model combining EfficientNet and Swin Transformer to integrate local and global features. Residual connections and positional embeddings are introduced to stabilize feature propagation and preserve spatial information, while dynamic weighting adaptively balances feature contributions.

Experimental results show that the proposed method outperforms both single-model and two-stage approaches, achieving an F1-score of 0.3930 and an AUC of 0.8449.

Keywords: Chest X-ray, Multi-label Classification, Data Imbalance, Cross Attention, EfficientNet, Swin Transformer

目錄

謝辭	I
摘要	II
ABSTRACT	III
目錄	IV
圖目錄	VI
表目錄	VII
公式目錄	VIII
附錄目錄	IX
第一章 緒論	1
1.1 研究背景	1
1.2 研究動機與目的	2
1.3 論文架構	3
第二章 文獻回顧	5
2.1 深度學習	5
2.1.1 卷積神經網路 (CNN)	5
2.1.2 高效網路 (EfficientNet)	7
2.1.3 轉換器與視覺轉換器	7
2.1.4 移動視窗視覺轉換器 (Swin Transformer)	9
2.1.5 遷移學習	10
2.2 資料不平衡處理策略	11
2.2.1 醫學影像的資料增強方法	11
2.2.2 醫學影像的上採樣策略	12
2.2.3 資料不平衡的長尾分布策略	13
2.3 特徵融合與集成學習策略	14
2.3.1 特徵融合與集成學習策略	14
2.3.2 注意力機制	15
2.3.3 交叉注意力機制	15
2.4 深度學習於胸腔 X 光疾病分類之應用與限制	16
第三章 研究方法	18
3.1 研究架構	18
3.2 資料前處理與影像增強	19
3.2.1 基於病人之資料集分割	20
3.2.2 資料前處理與資料增強	20
3.3 資料上採樣策略 (Oversampling)	21

3.4 特徵提取卷積網路：高效網路（EfficientNet）	23
3.5 基於 EfficientNet 之二階段分類架構	24
3.5.1 第一階段：二分類模型架構	25
3.5.2 第二階段：十四分類架構	26
3.5.3 第二階段：長尾分群分類架構	26
3.6 基於 EfficientNet 與 Swin Transformer 之交叉注意力特徵融合架構	27
3.6.1 全局特徵提取轉換器：移動視窗轉換器（Swin Transformer）	28
3.6.2 基於 EfficientNet 與 Swin Transformer 之交叉注意力模型架構	29
3.7 實驗硬體設備與訓練參數設定	33
第四章 實驗結果與討論	36
4.1 實驗資料集	36
4.2 評估方法	38
4.2.1 精確率（Precision）	38
4.2.2 靈敏度（Sensitivity）	38
4.2.3 特異度（Specificity）	39
4.2.4 F1-score	39
4.2.5 曲線下面積（AUC）	40
4.3 資料增強與上採樣策略結果分析	40
4.3.1 資料上採樣後分布	40
4.3.2 資料增強和上採樣成效分析	43
4.4 骨幹網路比較	45
4.5 二階段分類架構成效分析	48
4.5.1 第一階段二分類成效分析	48
4.5.2 第二階段十四分類架構成效分析	49
4.5.3 第二階段長尾分群分類架構成效分析	50
4.5.4 二階段分類架構綜合總結	52
4.6 基於 EfficientNet 與 Swin Transformer 交叉注意力特徵融合架構分析	53
4.6.1 Residual Connection 之影響	53
4.6.2 Positional Embedding 之影響	54
4.7 綜合討論	55
4.7.1 研究結果總結與分析	55
4.7.2 與現有文獻模型之比較	56
第五章 結論與未來展望	60
參考文獻	63
附錄	66

圖目錄

圖 3.1 研究架構流程圖	19
圖 3.2 資料增強示意圖	21
圖 3.3 二階段分類架構圖	25
圖 3.4 交叉注意力特徵融合架構圖	28



表目錄

表 3.1 實驗硬體設備與模型超參數設定	35
表 4.1 疾病中文名稱、完整英文標籤簡寫對照表	37
表 4.2 混淆矩陣	38
表 4.3 各類別上採樣後實際的樣本數與比例	41
表 4.4 不同的資料增強和上採樣方法平均分數比較	43
表 4.5 不同的資料增強對疝氣 (Hernia) 類別的影響	44
表 4.6 不同的資料增強對肺炎 (Pneumonia) 類別的影響	45
表 4.7 EfficientNet 和 Swin Transformer 平均分數比較	46
表 4.8 EfficientNet 和 Swin Transformer 各標籤分數比較	48
表 4.9 二分類模型預測 Finding 的各個指標分數	48
表 4.10 14 分類與原始模型排除 No Finding 後各指標平均分數	50
表 4.11 原始模型和第一階段二分類結合 14 分類模型架構各指標平均分數	50
表 4.12 原始模型頭尾類別與單獨頭尾模型平均分數	51
表 4.13 原始模型和第一階段二分類結合長尾分類模型架構各指標平均分數	52
表 4.14 交叉注意力架構導入殘差連接後之平均分數	53
表 4.15 交叉注意力架構導入位置嵌入後之平均分數	54
表 4.16 5 個模型與架構綜合比較	56
表 4.17 與其他現有研究之比較	59

公式目錄

公式 4.1 精確率	38
公式 4.2 靈敏度	39
公式 4.3 特異度	39
公式 4.4 F1-Score	40
公式 4.5 曲線下面積	40



附錄目錄

附錄 1 未經過資料增強 EfficientNet 各標籤分數	66
附錄 2 經過資料增強 EfficientNet 各標籤分數	67
附錄 3 上採樣至最少 1000 筆 EfficientNet 各標籤分數	68
附錄 4 上採樣至最少 2000 筆 EfficientNet 各標籤分數	69
附錄 5 上採樣至最少 3000 筆 EfficientNet 各標籤分數	70
附錄 6 上採樣至最少 4000 筆 EfficientNet 各標籤分數	71
附錄 7 上採樣至最少 1000 筆 SwinTransformer 各標籤分數	72
附錄 8 14 分類模型各標籤分數	73
附錄 9 11 分類尾部模型各標籤分數	74
附錄 10 3 分類頭部模型各標籤分數	74
附錄 11 二階段 14 分類各標籤分數	75
附錄 12 二階段結合長尾模型各標籤分數	76
附錄 13 Cross Attention 模型各標籤分數	77
附錄 14 Cross Attention 加上 Residual Connection 模型各標籤分數	78
附錄 15 完整 Cross Attention 特徵融合架構各標籤分數	79



第一章 緒論

1.1 研究背景

胸腔 X 光 (Chest X-ray) 影像是臨床醫學中最普遍且為成本較低的初步診斷工具，廣泛應用於肺部、心臟及胸膜等多種胸腔內部疾病的篩檢。然而，胸腔 X 光影像中往往包含複雜的解剖結構與重疊的組織器官，且早期病灶（如微小結節）的視覺特徵極不明顯，高度仰賴專業放射科醫師的豐富經驗進行判讀。隨著深度學習 (Deep Learning) 技術的蓬勃發展，將卷積神經網路 (CNN) 應用於輔助診斷系統以減輕醫師負擔並提高診斷效率，已成為近年來醫療影像分析領域的重要研究趨勢。

在胸腔 X 光的多標籤分類 (Multi-label Classification) 任務中，普遍面臨著極具挑戰性的資料不平衡 (Data Imbalance) 與長尾分佈 (Long-tailed Distribution) 問題。以著名的公開資料集 NIH ChestX-ray14 (Wang, et al., 2017) 為例，健康無異常 (No Finding) 的影像佔據了過半的資料量，而部分罕見疾病（如疝氣 Hernia 或肺炎 Pneumonia）的樣本數卻極度稀缺。若直接使用高度失衡的資料進行模型訓練，網路的梯度更新會被多數類別主導，導致模型對少數類別的病理特徵學習不足，進而在臨床應用上產生極高的漏診 (False Negative) 風險。

在模型架構的發展上，CNN 模型憑藉其強大的局部歸納偏置 (Local Inductive Bias)，在捕捉微小且局部的病灶上展現出卓越的效能。然而，受限於卷積核的局部感受野，CNN 在處理需要大面積、全局上下文資訊 (Contextual Information) 的疾病時往往力有未逮。為突破此限制，近年來基於自注意力機制 (Self-Attention) 的視覺轉換器 (Vision Transformer, ViT) 及其改良版本 Swin Transformer 被引入視覺任務中。Swin Transformer 具備強大的長距離依賴建模能力，能有效捕捉全局語義資訊，但在底層細微結構的提取效率上卻難以取代 CNN。因此，如何結合 CNN

與 Transformer 兩者的優勢，並在面對極端長尾分佈的醫學影像時給出更精準的診斷，成為當前醫學影像多標籤分類亟待突破的瓶頸。

1.2 研究動機與目的

針對上述醫療影像資料不平衡的困境，傳統的解決方案多採用資料上採樣（Oversampling）或構建多階段分類架構（如先判斷有無疾病，再進行細部分類）。然而，本研究在初步實驗中發現，盲目且過度的上採樣容易導致模型產生過度擬合（Overfitting）；而傳統的二階段串聯架構則面臨嚴重的「誤差向下傳遞」問題。當第一階段模型發生誤判時，後續模型將無從修正，反而大幅削弱了整體系統的預測效能。

基於上述觀察，本研究認為單一網路架構或單純的分階段分類架構具備限制。CNN（EfficientNet）與 Transformer（Swin Transformer）在視覺特徵的萃取上展現出良好的互補性，若能突破單一網路的侷限，並捨棄容易累積誤差的串聯式架構，改採雙流並行擷取特徵並進行深度融合的策略，將能同時發揮兩者的優勢。

因此，本研究旨在提出一套「基於 EfficientNet 與 Swin Transformer 之交叉注意力特徵融合架構」。有別於傳統簡單的向量拼接，本架構利用交叉注意力機制（Cross Attention），以 CNN 提取之局部病灶特徵為主動查詢向量（Query），引導 Swin Transformer 之全局上下文特徵（Key 與 Value）進行對齊與動態融合。此外，為解決深度融合時的特徵退化與空間資訊流失問題，本研究進一步引入殘差連接（Residual Connection）、位置嵌入（Positional Embedding）以及動態權重學習（Learning Weight）機制，使模型能夠自動學習分配三個模型特徵的權重。

綜合上述，本研究之具體目的可歸納為以下四點：

- 探討並制定適用於胸腔 X 光影像之資料平衡策略，透過微幅影像增強結合適度之上採樣門檻（如 1000 筆），在提升稀有疾病特徵多樣性的同時避免模型過度擬合。

- 驗證與比較不同分類架構（單一模型、二階段十四分類、二階段長尾分群）在處理多標籤醫學影像時的效能差異，分析傳統串聯式架構在誤差傳遞上的侷限性。
- 建構並實作基於 EfficientNet 與 Swin Transformer 之交叉注意力特徵融合架構，透過整合局部細節與全局特徵，以提升胸腔病徵的辨識準確度。
- 藉由消融實驗（Ablation Study），驗證殘差連接與位置嵌入等組件在特徵融合中的實質貢獻，為未來網路特徵融合提供實務設計參考。

1.3 論文架構

本篇論文共分為五個章節，各章節之內容概要如下所述：

- 第一章緒論：主要闡述本研究之研究背景與動機，指出胸腔 X 光多標籤分類與資料不平衡所面臨之挑戰，並描述本研究具體目的與預期貢獻，最後說明整篇論文之整體架構安排。
- 第二章文獻回顧：探討與本研究相關之核心技術與過往學術文獻。內容涵蓋深度學習模型架構（如卷積神經網路、EfficientNet、SwinTransformer）、醫學影像資料不平衡與長尾分佈之處理策略，以及注意力機制與交叉注意力（Cross Attention）在特徵上的應用發展。
- 第三章研究方法：詳細說明本研究之系統架構與實驗設計流程。首先介紹資料集分割方式，接著說明資料前處理流程、影像增強方法與資料上採樣策略。隨後介紹二階段分類架構之設計理念與實作流程，以及本研究提出之核心模型——基於 EfficientNet 與 Swin Transformer 之交叉注意力特徵融合架構。
- 第四章實驗結果與討論：呈現並分析各項實驗結果與評估指標（如 Precision、Sensitivity、Specificity、F1-score 與 AUC）。首先探討不同資料上採樣強度對模型分類效能之影響，並比較不同單一骨幹網路架構之優缺點。接著分析二階段分類架構於實際分類過程中所產生之誤差向下傳遞問題，並透過消融實驗

(Ablation Study) 驗證殘差連接 (Residual Connection) 與位置嵌入 (Positional Embedding) 等核心元件於交叉注意力特徵融合架構中的實際貢獻。最後，將本研究模型與相關研究方法進行比較，以評估所提出架構之分類效能與應用價值。

- 第五章結論與未來展望：總結本研究之各項實驗發現與實務成果，歸納所提出之交叉注意力融合架構在醫學影像多標籤分類上的優勢，並針對當前模型之局限性，提出具體且可行的未來研究方向。



第二章 文獻回顧

2.1 深度學習

深度學習 (Deep Learning) 為機器學習領域中基於人工神經網路所發展出的重要分支。傳統機器學習多仰賴領域專家進行人工特徵萃取，而深度學習則透過構建非線性網路結構，直接從大量原始資料中自動學習特徵表示 (LeCun, Bengio, & Hinton, 2015)，進而提升任務效能。隨著硬體運算效能的大幅躍進與大量數據的累積，深度學習在電腦視覺 (Computer Vision) 任務上取得了突破性的進展。近年來，研究學者陸續提出多種創新的網路架構，不僅在一般影像分類與物件偵測任務中表現優異，更被廣泛應用於醫學影像分析領域，為臨床輔助診斷提供強而有力的技術支持 (Litjens, et al., 2017)。

2.1.1 卷積神經網路 (CNN)

卷積神經網路 (Convolutional Neural Networks, CNN) 是專為處理具有空間排列特性的資料 (如二維影像) 而設計的深度前饋神經網路。CNN 的核心架構通常包含卷積層 (Convolutional Layer)、池化層 (Pooling Layer) 以及全連接層 (Fully Connected Layer)。其中，卷積層透過局部感受野 (Local Receptive Field) 與權重共享 (Weight Sharing) 機制，使模型具備局部歸納偏置 (Local Inductive Bias) 的特性。此特性代表模型假設影像中空間位置相近的像素通常具有較高的相關性，而距離較遠的像素之間相關性相對較低。基於此概念，多組卷積核會在輸入影像上進行滑動運算，逐步擷取邊緣、角點及紋理等低階視覺特徵，再經由多層卷積網路逐層整合，最終形成具有更高層次的特徵表示 (Goodfellow, Bengio, & Courville, 2016)。

在完成初步特徵擷取後，池化層會進一步對特徵圖進行降維與取樣，在降低特徵表示的空間維度，同時保留主要特徵資訊。此操作不僅能減少後續網路層的計算負擔，也能提升模型對輸入影像中位置變化的適應能力，使目標物即使產生輕微位

移，仍能維持穩定的辨識效果。最後，全連接層則負責將前述萃取出的高階特徵進行整合與分類，透過特徵映射將其轉換至符合任務需求的輸出維度，以產生最終分類結果。

自 2012 年 AlexNet (Krizhevsky, Sutskever, & Hinton, 2012) 於 ImageNet 競賽中取得突破性成果後，CNN 逐漸成為電腦視覺領域中的主流模型，並促使後續多種高效能網路架構的發展，知名的模型例如 ResNet、DenseNet 與 EfficientNet 等。

在醫學影像領域中，ResNet 與 DenseNet 亦被廣泛應用於胸腔 X 光影像辨識任務。其中，史丹佛大學研究團隊提出的 CheXNet 為 DenseNet 應用於胸腔 X 光分析的代表性研究。該研究採用 DenseNet 作為主要模型，應用於胸腔 X 光中的疾病偵測，其中的診斷表現甚至超越專業放射科醫師的水準 (Rajpurkar, et al., 2017)。

此外，本研究所使用之資料集為美國國立衛生研究院 (National Institutes of Health, NIH) 所發布之 ChestX-ray14 資料集，該資料集源自於早期提出的 ChestX-ray8 資料集擴充而來。原始 ChestX-ray8 研究蒐集並整理了胸腔 X 光影像資料，並針對多種深度學習架構進行疾病分類效能比較，包括 ResNet、VGGNet、GoogleNet 等多個模型。最後實驗結果顯示，ResNet 於胸腔 X 光疾病分類任務中具有較佳的分類表現，證明深層殘差架構也適用於醫學影像特徵學習 (Wang, et al., 2017)。因此，ResNet 與 DenseNet 亦成為後續胸腔 X 光疾病辨識研究中常見的基礎模型架構。

儘管 ResNet 與 DenseNet 等傳統卷積神經網路在胸腔 X 光等醫學影像辨識任務中具有良好的分類效能，但當模型規模持續擴展時，模型面臨效能與計算成本之間的權衡問題。傳統卷積神經網路通常透過單獨增加網路深度、寬度或輸入解析度等單一維度提升特徵擷取能力，然而此類擴展方式容易造成參數量、運算量與記憶體需求大幅增加，而分類效能的提升幅度卻逐漸有限，無法達到與模型規模成比例的改善。

以 ResNet 為例，其透過殘差連接改善深層網路訓練問題，但隨著網路深度增加，模型複雜度與計算成本亦同步提升，效能增益卻逐漸有限。DenseNet 雖透過密集連接促進特徵重用與梯度傳遞，但需保留並串接多層特徵資訊，使記憶體需求與運算負擔大幅增加。因此，傳統卷積神經網路在擴展模型規模以提升分類效能時，容易面臨成本增加但效能提升有限的問題。

2.1.2 高效網路 (EfficientNet)

為改善前一節所述之限制，後續研究開始探索更有效率的模型縮放策略，透過平衡調整網路深度、寬度與輸入解析度，以提升模型效能並降低計算成本。Tan 與 Le 提出 EfficientNet 架構，其不同於傳統卷積神經網路僅針對單一維度進行模型擴展，提出複合縮放方法 (Compound Scaling Method)，利用固定的複合係數 (Compound Coefficient) 同步調整網路深度、寬度與輸入影像解析度，使模型在不同運算規模下皆能維持良好的效能與效率 (Tan & Le, 2019)。

在模型建構階段，研究團隊首先透過神經架構搜尋 (Neural Architecture Search, NAS) (Zoph & Le, 2016) 技術自動設計出基礎網路 EfficientNet-B0，使其在分類準確率與運算量之間取得良好的平衡。隨後，透過複合縮放方法，以固定縮放係數逐步擴展 EfficientNet-B0，發展出 EfficientNet-B1 至 EfficientNet-B7 等不同規模模型。相較於傳統卷積神經網路，EfficientNet 能以較少的參數量與運算成本達到更高的分類效能，展現良好的參數利用效率與特徵擷取能力。。

由於兼具效能與效率優勢，EfficientNet 適合應用於計算資源受限或需處理高解析度影像的醫學影像分析任務，近年來也被廣泛作為研究醫療影像分類或電腦輔助診斷系統中的骨幹網路。(Marques, Agarwal, & De la Torre Díez, 2020)。

2.1.3 轉換器與視覺轉換器

儘管卷積神經網路 (Convolutional Neural Networks, CNN) 在影像辨識任務中取得良好成果，並廣泛應用於醫學影像分析，但其基於局部感受野 (Local Receptive

Field) 的特性，使模型在捕捉影像中遠距離區域的關聯性時受到限制。若需擴大感受野，通常需透過增加網路深度或堆疊更多卷積層實現，然而此方式可能大幅提高模型複雜度，也會使特徵傳遞過程中造成資訊損失。

為改善傳統序列模型在長距離關係建模上的限制，Vaswani 等人在自然語言處理領域於 2017 年提出 Transformer 架構 (Vaswani, et al., 2017)。不同於依靠序列逐步處理資訊的循環神經網路 (Recurrent Neural Networks, RNN)，Transformer 基於注意力機制 (Attention Mechanism) 進行特徵學習，透過自注意力機制 (Self-Attention Mechanism) 計算不同元素間的關聯性，使模型能同時考慮整體資訊，提升長距離依賴關係的建模能力。

受到 Transformer 在自然語言處理領域成功的啟發，Dosovitskiy 等人進一步將其應用於電腦視覺領域，提出視覺轉換器 (Vision Transformer, ViT) (Dosovitskiy, et al., 2020)。ViT 將影像切割為固定大小的影像區塊 (Image Patches)，並將其轉換為特徵向量後輸入 Transformer 編碼器，透過自注意力機制學習影像區域間的關聯資訊。然而，由於 ViT 缺 CNN 所具備的局部歸納偏置 (Local Inductive Bias)，通常需要大量資料進行預訓練才能達到良好效能。

為降低 ViT 對大規模資料集的依賴，Touvron 等人提出資料高效率視覺轉換器 (Data-efficient Image Transformer, DeiT) (Touvron, et al., 2021)，透過知識蒸餾 (Knowledge Distillation) 技術改善 Transformer 在有限資料條件下的訓練能力，使其更適合應用於資料規模受限的影像分類任務。

近年來，Transformer 架構亦逐漸應用於胸腔 X 光疾病分類任務。例如，Jalalifar 與 Huang 分別提出基於 DeiT 與 ViT 的分類模型，也在胸腔 X 光疾病分類任務中取得良好的分類效能 (Jalalifar & Sadeghi-Naini, 2022) (Huang, Ma, Yang, & Wang, 2024)。

2.1.4 移動視窗視覺轉換器 (Swin Transformer)

然而，根據前節所述，ViT 及其改良架構 DeiT 雖能提升 Transformer 於影像分類任務中的應用能力，其中 DeiT 透過知識蒸餾機制降低模型學習複雜度，改善資料需求較高的問題，但兩者仍採用全局自注意力機制，其計算成本會隨影像區塊數量增加而快速提升此外，ViT 與 DeiT 通常將輸入影像切分為固定大小的影像區塊進行特徵學習，缺乏階層式特徵表示能力，因此較難同時捕捉影像中不同尺度的病灶特徵。基於上述限制，Liu 等人提出 Swin Transformer，透過局部視窗注意力機制降低自注意力計算負擔，並結合階層式架構建立多尺度特徵表示，使模型能兼顧計算效率與特徵學習能力 (Liu, et al., 2021)。

Swin Transformer 融合卷積神經網路 (CNN) 的階層式特徵提取概念，透過逐層調整特徵圖的維度，建立階層式特徵學習方法。並提出基於視窗的多頭自注意力機制 (Window-based Multi-head Self-Attention, W-MSA)，限制自注意力計算僅於各視窗內進行，使計算複雜度由全局注意力機制的平方級成長降低至近似線性成長。然而，固定視窗劃分方式會限制不同視窗間的資訊交流，因此 Swin Transformer 進一步提出移動視窗機制 (Shifted Window-based Multi-head Self-Attention, SW-MSA)。透過在相鄰網路層間交替使用一般視窗與移動視窗，使相鄰區域間能建立跨視窗資訊連結，同時維持較低的計算成本。

透過上述設計，Swin Transformer 在降低高解析度影像分析運算成本的同時，兼顧局部與全局特徵資訊的學習能力。此外，其階層式架構可逐步提取不同尺度的影像特徵，使模型更適合應用於病灶大小差異明顯且具有複雜空間結構的醫學影像分析。相關研究亦證實，Swin Transformer 在胸腔 X 光疾病分類任務中展現出良好的分類效能 (Taslimi, Taslimi, Fathi, Salehi, & Rohban, 2022)。




圖 2.1 Swin Transformer 架構圖

2.1.5 遷移學習

在醫學影像分析的研究中，收集大規模且具備專業醫師標註的高品質資料集往往需要耗費極高的時間與人力成本。當面對這類資料匱乏的情境時，從零開始訓練一個深層神經網路極易陷入過度擬合（Overfitting）的困境，進而嚴重影響模型的泛化能力。而遷移學習（Transfer Learning）是深度學習領域中用以克服這種困境的一項關鍵技術。其核心思想是將模型在來源領域（Source Domain）上預先學習到的龐大知識與權重參數，轉移並重新應用於目標領域（Target Domain）的學習任務中（Pan & Yang, 2009）。

研究人員通常會先利用擁有千萬級別影像的大型公開資料集，如 ImageNet (Deng, et al., 2009) 對深度學習模型進行預訓練（Pre-training），使網路在淺層具備辨識邊緣、形狀與基本紋理等通用視覺特徵的能力。接著，再將此預訓練模型遷移至特定領域，如醫學影像分析任務中進行微調（Fine-tuning）。在微調階段，模型以預訓練權重作為初始化參數，並透過目標領域資料更新整個網路的參數，使模型原有的視覺特徵表示能夠逐步調整，以適應醫學影像中疾病相關特徵的辨識需求 (Tajbakhsh, et al., 2016)。研究亦證實，透過遷移學習策略皆能有效降低模型訓練所需的資料量與收斂時間，並改善醫學影像樣本不足所造成的限制，進而提升模型在醫學影像分類任務中的預測效能與泛化能力。

2.2 資料不平衡處理策略

資料不平衡 (Data Imbalance) 是機器學習與深度學習應用中極為常見且棘手的挑戰。當資料集中不同類別之間存在明顯的樣本數量差異時，深度學習模型在訓練過程中容易受到資料分布影響，使模型傾向於學習多數類別 (Majority Class) 的特徵，進而產生預測偏誤 (Bias)。此現象會降低模型對少數類別 (Minority Class) 特徵的學習能力 (Buda, Maki, & Mazurowski, 2018)。在醫學影像分析領域中，資料不平衡問題更加明顯，原因在於真實臨床資料通常具有疾病分布不均的特性，例如正常影像數量往往遠高於罕見疾病影像。若直接使用高度不平衡的資料集進行模型訓練，模型可能傾向將大部分樣本分類為正常類別，以取得較高的整體準確率 (Accuracy)。然而，在實際醫療診斷情境中，將疾病樣本誤判為正常樣本所造成的假負例 (False Negative) 可能延誤疾病發現，其影響通常高於將正常樣本誤判為疾病樣本。因此，若模型僅依賴整體準確率作為效能衡量，可能無法真實反映其診斷能力，並增加實際應用上的醫療風險。基於上述原因，如何針對資料不平衡問題採取適當的處理策略，以提升模型對少數類別特徵的學習能力，已成為醫學影像模型訓練中的重要研究課題之一。

2.2.1 醫學影像的資料增強方法

為緩解醫學影像資料集中嚴重的資料不平衡問題，直接調整訓練資料分布是一種常見且有效的處理方式。其中，資料增強 (Data Augmentation) 技術可透過增加少數類別樣本數量與提升資料多樣性，改善模型對少數類別特徵的學習能力，因此被廣泛應用於醫學影像分類任務中 (Shorten & Khoshgoftaar, 2019)。

然而，醫學影像具備嚴格的解剖結構與病理語義，傳統自然影像中過度的轉換操作 (如大幅度裁切、強烈的色彩轉換) 容易破壞真實的病灶特徵。因此，適用於醫學影像的資料增強必須兼顧特徵多樣性與病理真實性。實務上，最適合且安全的幾何轉換包含微幅的隨機旋轉、平移與縮放，這能有效模擬病患在拍攝儀器前不同

姿勢與位置的微小變異。這些操作不僅能消除不同醫療設備或曝光條件所造成的影像差異，更能迫使網路模型學習到具體的疾病特徵 (Chlap, et al., 2021)。

2.2.2 醫學影像的上採樣策略

為了解決類別不平衡問題，上採樣 (Oversampling) 是縮小不同類別資料量差距的重要方法。其主要透過增加少數類別樣本數量，使資料分布更加平衡，以降低模型偏向多數類別的問題，進而提升少數疾病類別的辨識能力。目前胸腔 X 光影像分類研究中，常見的上採樣方法包含傳統重複抽取、少數類別合成過採樣技術 (Synthetic Minority Oversampling Technique, SMOTE) 以及生成式資料擴增方法等等。

傳統重複抽取方法通常搭配旋轉、翻轉、裁切、亮度調整等影像增強技術，以增加少數類別資料多樣性。Ashari 等人探討隨機過採樣於胸腔 X 光肺部疾病分類中的影響，結果顯示相較於原始不平衡資料集，採用隨機過採樣後模型準確率提升 7.52%，證明傳統上採樣方法能有效改善類別不平衡問題 (Ashari Rakhmat & Muhammad Yudiantira, 2024)。

SMOTE 則透過少數類別樣本間的特徵關係，在特徵空間中產生新的合成樣本，以改善資料分布不均。例如 Chamseddine 等人將 SMOTE 應用於 COVID-19 胸腔 X 光影像分類任務，研究結果顯示，結合 SMOTE 後能有效提升少數疾病類別的分類表現 (Chamseddine, Mansouri, Soui, & Abed, 2022)。

此外，隨著生成式人工智慧技術發展，生成對抗網路 (Generative Adversarial Network, GAN) 與擴散模型 (Diffusion Model) 亦逐漸應用於醫學影像資料擴增。Sundaram 與 Hulkun 利用 GAN 生成胸腔 X 光疾病影像並加入訓練資料，結果顯示生成影像能提升少數疾病類別的辨識能力，展現生成式資料擴增於醫療影像分類任務中的潛力 (Sundaram & Hulkund, 2021)。Schaudt 等人 (2023) 進一步將擴散模型應用於胸腔 X 光資料集，發現生成資料能改善類別分布並提升少數類別學習效

果 (Schaudt, et al., 2023)。

綜合上述研究可知，上採樣方法能有效改善胸腔 X 光影像分類中的類別不平衡問題。無論傳統重複抽取、SMOTE 或生成式資料擴增方法，皆有研究證實其能提升少數類別的辨識能力。然而，不同上採樣方法對模型整體效能的影響仍會受到資料分布、疾病類別特性以及資料擴增方式等因素影響。

2.2.3 資料不平衡的長尾分布策略

在許多真實世界的分類任務中，資料集的類別分布常呈現極端的長尾分布 (Long-tailed Distribution)。此種分布特性意指少數「頭部類別 (Head Classes)」擁有大量樣本，而多數「尾部類別 (Tail Classes)」僅包含極少量資料。當直接使用此類長尾資料訓練單一深度學習模型時，由於頭部類別的樣本數遠多於尾部類別，因此其對模型權重更新的影響較大，使模型逐漸偏向學習頭部類別的特徵，進而降低對尾部類別的辨識能力，造成整體分類效能失衡 (Liu, et al., 2019)。

為改善單一模型於長尾資料上的學習限制，近年來研究提出「分而治之 (Divide-and-Conquer)」的多專家集成架構 (Multi-Expert Architecture)。其核心概念在於，將原本涵蓋所有類別的學習任務，依據資料分布劃分為頭部類別、尾部類別等多個子集合，並分別訓練對應的專家模型，使各模型專注於不同類別分布的特徵學習 (Xiang, Ding, & Han, 2020)。

此種架構透過將頭部與尾部類別分別學習，再於推論階段融合各專家模型的輸出結果，可有效降低尾部類別在訓練過程中受到頭部類別壓制的情形。由於各專家模型能針對不同資料分布建立更具代表性的特徵表示，因此在維持頭部類別高辨識能力的同時，亦能提升尾部少數類別的分類效能，進而改善長尾資料所造成的類別不平衡問題。

2.3 特徵融合與集成學習策略

2.3.1 特徵融合與集成學習策略

在深度學習的醫學影像分析中，特徵融合（Feature Fusion）與集成學習（Ensemble Learning）是提升模型泛化能力與診斷準確率的重要技術。集成學習主要是透過整合多個獨立模型的預測結果，以降低單一模型的偏差與誤判率（Dietterich, 2000）。在胸腔 X 光分類任務中，常見的集成學習策略包含如機率平均、機率加權平均，以及利用分類器整合多個模型輸出的堆疊學習（Stacking）。例如，Ashraf 等人在 NIH ChestX-ray14 資料集上分別訓練六個分類模型，並比較如機率平均、XGBoost（堆疊學習）以及利用差分演化演算法（最佳化機率加權平均）等集成學習方法，實驗結果顯示，相較於其他方法，以差分演化最佳化所得之加權集成具有最佳的分類效能（Ashraf, Mamun, Abdullah, & Alam, 2023）。

而相較於決策層的集成方式，特徵融合則是在模型內部整合不同來源的特徵，將來自不同深度、不同模型架構或不同感受野的特徵共同用於後續分類，使模型能同時利用多個模型提取出來的特徵資訊，以提升辨識能力。常見的融合方式包括特徵拼接（Concatenation）與元素相加（Element-wise Addition）。例如 Chen 等人提出雙分支網路架構，利用特徵融合整合 ResNet 與 DenseNet 不同視角與感受野所擷取的資訊，得以提升胸腔疾病分類效能（Chen, Li, Guo, & Lu, 2019）。

然而，傳統特徵融合方法仍存在限制。以特徵拼接為例，雖能保留不同模型所擷取的資訊，但僅將特徵向量直接串接，缺乏不同特徵來源之間的交互學習能力。例如，卷積神經網路擅長捕捉局部紋理與細節資訊，而 Transformer 則能學習全域空間關係，單純拼接方式難以有效建立兩者之間的關聯。

因此，近年研究逐漸探索更具自適應能力的融合方法，使模型能學習不同特徵的重要性。其中，注意力機制（Attention Mechanism）透過建立特徵間的關聯性，使模型能選擇性關注具判別能力的資訊，降低無關特徵造成的干擾，已開始被應用

於醫學影像分類與多特徵融合任務中。

2.3.2 注意力機制

注意力機制 (Attention Mechanism) 的概念源自於人類視覺系統的認知模式。當人類觀察複雜場景時，大腦會自動將視覺資源與注意力集中於少數關鍵區域，同時忽略無關的背景雜訊。在深度學習領域中，注意力機制最早被廣泛應用於自然語言處理 (NLP) 領域 (Bahdanau, Cho, & Bengio, 2014)，用以解決長序列資訊傳遞過程中的特徵流失問題。隨後，此概念被成功引入電腦視覺 (Computer Vision) 領域，賦予神經網路根據特徵重要性動態調整權重的能力。

在醫學影像多標籤分類任務中，不同疾病的特徵分佈差異極大。透過導入注意力機制，模型能夠自適應地聚焦於微小的病理區域，並主動降低非病灶組織或醫學儀器邊界等無關背景雜訊的干擾 (Schlemper, et al., 2019)。這項機制不僅大幅提升了特徵萃取的精準度，更能提升模型對關鍵病灶特徵的辨識能力，因此已廣泛應用於醫學影像分類、目標偵測及多特徵融合等任務中。

2.3.3 交叉注意力機制

Transformer 在建模全域特徵關係方面具有優勢，但由於其特徵建構方式與 CNN 不同，在局部紋理與細微結構資訊的建模上，兩者各具優勢，因此具有高度互補性。 (Dai, Liu, Le, & Tan, 2021)。在複雜的醫學影像多標籤分類任務中，病灶可能呈現極小的局部微特徵，也可能分佈於廣泛的全局器官結構中。若能破除單一網路的侷限，將 CNN 所萃取的豐富局部空間特徵與 Transformer 所提取的全局上下文特徵進行深度結合，便能同時發揮兩者的優勢。

為達成此一深度的特徵交互作用，交叉注意力機制 (Cross Attention) 成為了最為關鍵的技術。有別於自注意力機制 (Self-Attention) 中查詢 (Query)、鍵 (Key) 與值 (Value) 皆來自於同一輸入來源，交叉注意力機制的核心在於處理兩個不同來源的特徵序列 (Chen, Fan, & Panda, 2021)。具體而言，該機制會將其中一個特徵

分支的輸出作為查詢向量，並將另一個特徵分支的輸出作為鍵向量與值向量。透過計算兩者之間的注意力權重，模型能夠自動評估並對齊兩種不同特徵表示之間的潛在關聯性，因此，交叉注意力機制能夠促進不同特徵來源之間的資訊互動與互補，使融合後的特徵同時保留局部細節與全域語意資訊，進一步提升模型在醫學影像分類任務中的表現。

2.4 深度學習於胸腔 X 光疾病分類之應用與限制

綜合前面章節所述，胸腔 X 光疾病分類研究隨著深度學習技術發展逐漸由單一卷積神經網路模型拓展至多元化架構。早期研究多採用 CNN 架構進行疾病特徵學習，例如 Rajpurkar 等人提出 CheXNet 模型 (Rajpurkar, et al., 2017)，以及 Wang 等人建立 NIH ChestX-ray14 資料集並評估多種深度學習模型於胸腔疾病分類任務中的應用 (Wang, et al., 2017)，到陸續導入 EfficientNet 等高效率卷積架構 (Marques, et al., 2020)，以及 ViT (Huang, et al., 2024)、DeiT (Jalalifar & Sadeghi-Naini, 2022) 與 Swin Transformer (Taslimi, et al., 2022) 等基於注意力機制之模型 (Murphy, et al., 2022)，以提升模型特徵表示能力與運算效率。

然而，由於胸腔 X 光資料集通常具有疾病樣本分布不均的特性，研究亦廣泛探討資料增強與上採樣策略，以改善少數疾病類別樣本不足所造成的分類偏差，例如利用傳統影像轉換、隨機過採樣 (Ashari Rakhmat & Muhammad Yudiantira, 2024)、SMOTE (Chamseddine, et al., 2022) 及生成式資料擴增方法提升模型對少數類別之學習能力 (Sundaram & Hulkund, 2021; Schaudt, et al., 2023)。此外，由於不同模型架構所擷取之影像特徵具有互補性，近年研究亦逐漸採用特徵融合與集成學習策略，透過整合多個模型之預測結果或特徵資訊提升分類能力，例如 Chen 等人結合不同卷積架構進行特徵融合 (Chen, et al., 2019)，以及 Ashraf 等人比較多種集成方法於 NIH ChestX-ray14 資料集上的應用 (Ashraf, et al., 2023)。

然而，現有胸腔 X 光深度學習研究多著重於提升模型分類效能，且多數實驗

依賴較高運算資源之環境完成模型訓練與微調。例如，部分研究採用雲端運算平台進行模型開發，其中 Chamseddine 等人於胸腔 X 光疾病分類任務中使用 Google Colab 環境，配置 25GB 記憶體執行資料平衡與模型訓練；亦有研究透過多張高階圖形處理器提升模型訓練效率，如 SynthEnsemble 使用兩張 NVIDIA T4 GPU（共 32GB 顯示卡記憶體），DualCheXNet 則使用四張 TITAN Xp GPU（共 48GB 顯示卡記憶體）進行模型訓練。雖然上述高效能運算環境能提供充足計算能力以支援複雜模型架構，但亦提高人工智慧輔助診斷系統於資源有限地區實際部署與維護之門檻。對於部分偏遠國家或地區而言，若缺乏穩定的高效能運算設備或網路資源，地方診所與區域醫院若需依據自身資料進行模型微調，甚至重新訓練模型，仍可能受到硬體資源限制。因此，如何於有限運算資源條件下維持良好分類效能，成為胸腔 X 光輔助診斷系統實際應用的重要考量。

其中，圖形處理器顯示記憶體容量是影響深度學習模型訓練可行性的重要因素之一。當顯示記憶體不足時，通常需降低批次大小以避免記憶體不足錯誤。然而，較小的批次大小會降低單次參數更新所使用的樣本數，使梯度估計產生較大變異，可能增加訓練過程的不穩定性。此外，若透過增加梯度累積次數維持較大等效批次大小，雖可降低單次記憶體需求，但亦可能降低參數更新頻率，影響整體訓練效率。因此，如何在受限硬體環境下兼顧顯示記憶體使用量、模型收斂穩定性與分類效能，是深度學習模型實際部署時的重要挑戰。

綜合上述可知，現有胸腔 X 光疾病分類方法已透過不同深度學習架構、資料增強策略及模型融合方法提升分類效能。然而，多數研究主要著重於模型效能提升，對於模型訓練所需硬體資源與實際部署限制之探討相對有限。因此，在維持良好分類能力的同時降低模型對高階運算設備之依賴，仍是胸腔 X 光人工智慧輔助診斷系統推廣應用的重要課題。

第三章 研究方法

3.1 研究架構

本研究採用公開之 NIH Chest X-rays 資料集作為胸腔 X 光影像訓練與測試來源。於取得影像資料後，首先進行影像之資料前處理。針對醫學影像常見之資料類別不平衡問題，研究進一步導入資料上採樣策略，以改善不同疾病類別間之樣本分布差異。

接著，處理後之影像資料將輸入至本研究探討之兩大核心架構進行模型訓練。考量顯示卡記憶體限制，本研究採用梯度累積策略，以批次大小 8 模擬批次大小 16 之訓練效果。本研究主要探討兩種胸腔 X 光疾病分類架構，其一為「二階段分類架構」，首先透過第一階段進行正常與異常影像之二分類，若判定為具有疾病特徵，則進一步進入第二階段進行細部疾病分類（十四分類或長尾分群，Long-tail Grouping）；其二為「交叉注意力特徵融合架構」，結合 EfficientNet 與 Swin Transformer 分別擷取影像之局部與全局特徵，並透過交叉注意力機制（Cross Attention）進行特徵融合。最後，根據模型之疾病預測結果進行效能評估與比較分析，整體研究流程如圖 3.1 所示。




圖 3.1 研究架構流程圖

3.2 資料前處理與影像增強

在深度學習模型訓練中，資料的品質與分割方式直接影響模型的泛化能力與評估的準確性。為了確保模型能學習到實際的病理特徵，而非僅僅記憶特定病人的解剖結構，本研究在資料前處理階段執行了嚴謹的資料集分割與影像增強策略。

3.2.1 基於病人之資料集分割

在醫學影像分析中，同一名患者通常擁有多張不同時間點所拍攝的影像。若將同一病人的影像隨機分配至訓練集與測試集。這些影像雖然不是完全相同，但因為來自同一位患者，因此會共享大量相似特徵，例如肺部結構、骨骼形狀、器官位置。若在資料切分時，直接以「影像」為單位進行隨機分配，而不是以「病人」為單位切分，便可能發生同一名患者的部分影像被分配到訓練集，另外部分影像被分配到測試集的情況。此時模型在訓練階段已經看過該患者的特徵，因此在測試時，模型可能不是學會真正的疾病判斷能力，而是記住該病人的影像特徵，進而產生較高的預測結果。

因此，本研究採用基於病人 ID 的分割方式，將所有病人隨機劃分為三個獨立集合。分割比例設定為 70% 作為訓練集 (Training Set)、10% 作為驗證集 (Validation Set) 以及 20% 作為測試集 (Test Set)。透過這種分割方法，測試集中的病人完全未曾出現在訓練過程中，以此模擬臨床上模型對於新病患影像的診斷能力。

3.2.2 資料前處理與資料增強

資料增強 (Data Augmentation) 是一種透過「修改原始影像」來增加訓練資料的方法，目的是讓模型看過更多不同變化的資料，進而提升模型的學習能力與穩定性。本研究針對訓練集影像設計了一套隨機變換流程，旨在模擬實際臨床拍攝時可能產生的角度偏差與位置偏移。

首先將所有原始影像縮放至指定尺寸 384×384 ，並以 50% 的機率進行隨機水平翻轉 (Random Horizontal Flip)。目的是透過改變病灶在影像中的空間位置，可降低模型對固定位置特徵的依賴，強化模型對病灶紋理與形狀特徵的學習能力。接著，從以下三種變換中隨機挑選一項執行，以確保影像在訓練過程中具有高度的多樣性但不至於過度失真：

- 微小旋轉 (Random Rotation)：於 $\pm 7^\circ$ 範圍內進行旋轉，模擬拍攝角度的偏差。

- 等比例縮放 (Random Scaling)：於 0.9 至 1.1 倍之間縮放，模擬病患與設備間距離的差異。
- 平移 (Random Translation)：於 X 軸與 Y 軸方向進行 $\pm 5\%$ 以內的隨機平移，模擬影像構圖的位置變動。

最後，利用 ImageNet 資料集的標準平均值 (Mean) 與標準差 (Std) 進行正規化處理，其平均值設定為 $[0.485, 0.456, 0.406]$ ，標準差為 $[0.229, 0.224, 0.225]$ 。此步驟是為了讓醫療影像的數值範圍貼近預訓練數值，有助於發揮轉移學習的效益。




圖 3.2 資料增強示意圖

3.3 資料上採樣策略 (Oversampling)

在醫療影像深度學習任務中，多標籤分類問題普遍面臨嚴重的資料類別不平衡現象。以本研究採用之 NIH ChestX-ray14 資料集為例，各疾病類別之樣本數量差異極大。若直接將資料集投入模型訓練，會使模型權重過度偏向多數類別，進而

降低對稀有疾病特徵之學習能力，並嚴重影響少數類別之辨識效能。

為了改善資料類別不平衡問題，並探討最適合模型訓練的資料分布，本研究設計不同強度的上採樣（Oversampling）實驗。針對原始樣本數不足的少數類別，分別將各疾病類別樣本數擴增至至少 1000、2000、3000 及 4000 筆，比較不同上採樣強度對模型效能之影響。

儘管近年來 SMOTE、生成對抗網路（GAN）及擴散模型（Diffusion Model）等資料上採樣方法皆已證實能有效改善資料類別不平衡問題，本研究仍選擇採用重複抽取搭配資料增強作為上採樣策略，主要考量為計算資源需求、模型複雜度以及研究環境限制。相較於傳統重複抽取方法，GAN 與擴散模型需額外訓練生成模型，不僅增加整體訓練流程，也對硬體設備需要更高要求。以 Schaudt 等人的研究為例 (Schaudt, et al., 2023)，其將擴散模型應用於胸腔 X 光影像資料擴增，實驗環境採用兩張 NVIDIA GeForce RTX 3090 顯示卡進行模型訓練。相較於一般研究環境，此配置具有較高的運算能力與顯示記憶體資源，顯示生成式資料擴增方法通常需要較高的硬體需求，才能支援生成模型的訓練與大量影像生成流程。

另一方面，Chamseddine 等人在研究裡面提到，該研究使用 Google Colab 平台進行模型訓練，實驗環境提供 25 GB RAM 與 GPU 運算資源，但未詳細說明 GPU 型號與顯示記憶體容量。由於硬體資源限制，作者在應用 SMOTE 時將輸入影像解析度由 224×224 降低至 128×128 ，以降低記憶體需求，並指出 SMOTE 需要較高的記憶體與運算成本 (Chamseddine, Mansouri, Soui, & Abed, 2022)。本研究則採用 384×384 像素胸腔 X 光影像作為模型輸入，實驗環境配備 16 GB DDR5 主記憶體及單張 NVIDIA RTX 4060（8 GB 顯示記憶體）。在有限的硬體資源下，若再額外加入 SMOTE 的特徵合成流程，將可能超出硬體可負荷範圍，導致資料處理與模型訓練流程無法有效執行，因此不採用 SMOTE 作為本研究之上採樣方法。

綜合上述考量，本研究採用計算成本較低且容易實作的重複抽取搭配基礎資料增強作為上採樣策略。此方法無需額外建立生成模型或進行特徵空間合成運算，

即可透過旋轉、翻轉、裁切、亮度調整及雜訊加入等方式提升少數類別樣本多樣性，在有限的硬體資源下兼顧訓練效率與類別不平衡改善效果。

3.4 特徵提取卷積網路：高效網路（EfficientNet）

本研究初期曾評估 ResNet、DenseNet 與 EfficientNet 作為卷積神經網路骨幹架構之可行性。其中，ResNet 透過殘差連接（Residual Connection）有效改善深層網路訓練時的梯度消失問題；DenseNet 則藉由密集連接（Dense Connection）提升特徵重複利用率，三者皆已廣泛應用於醫學影像分析，並於胸腔 X 光疾病分類任務中展現良好的分類效能。然而，ResNet 與 DenseNet 主要透過增加網路深度、堆疊更多卷積層，以及增加特徵通道數與特徵維度來提升模型表達能力，此類擴展方式雖能增強特徵學習能力，隨之帶來大幅增加的參數量與運算成本，使其在計算資源受限的醫療應用場域中，部署效率與運算效能受到一定程度的限制。相較之下，EfficientNet 提出複合縮放法（Compound Scaling），透過協調網路深度、寬度與輸入影像解析度的縮放策略，在維持較少參數量與較低運算成本的同時，仍能保持優異的特徵提取能力與分類效能。因此，本研究最終選擇 EfficientNet 作為卷積神經網路特徵提取模型，並於實作中透過 Python 的 timm（PyTorch Image Models）函式庫載入具備預訓練權重的 EfficientNet-B5 模型。

在本研究提出的「二階段分類架構」與「交叉注意力特徵融合架構」中，皆採用 EfficientNet 作為主要特徵提取網路。在二階段分類架構中，EfficientNet 分別作為第一階段有無疾病二分類模型，以及第二階段細部疾病分類模型的骨幹網路。在交叉注意力特徵融合架構中，EfficientNet 則作為卷積神經網路（CNN）分支，負責擷取胸腔 X 光影像中的局部紋理與細節特徵，並與 Swin Transformer 所提取的全域特徵透過交叉注意力（Cross-Attention）機制進行融合，以整合不同尺度的影像資訊，提升模型對複雜病灶特徵的辨識能力。

3.5 基於 EfficientNet 之二階段分類架構

在處理複雜的醫學影像分類任務時，單一網路常面臨嚴重的資料不平衡問題。以本研究使用的 NIH ChestX-ray14 資料集為例，無異常（No Finding）的樣本數量遠大於其他病徵類別的數量，導致模型在分類時容易產生預測錯誤，傾向將少數異常類別誤判為正常。

為突破資料不平衡的瓶頸，本研究提出了一套二階段階層式（Two-stage Hierarchical）的分類架構。第一階段專注於「有無疾病」的二分類篩選；第二階段則設計了兩種的分類策略進行比較，具體架構如圖 3.3 所示。本節將詳述其模型設計與訓練機制。






圖 3.3 二階段分類架構圖

3.5.1 第一階段：二分類模型架構

在第一階段中，模型負責進行二分類任務，判斷輸入影像是否具備病徵。此階段將資料集中的標註變更為 0 (No Finding) 與 1 (Finding)，亦即區分「有病徵」與「無病徵」兩種狀態。若第一階段判定結果為「無病徵」，則終止預測；若判定

為「有病徵」，該影像才會進入第二階段，進行具體的疾病類別辨識。

3.5.2 第二階段：十四分類架構

在第一階段完成初步二分類篩選後，被判定為具有病徵之胸腔 X 光影像將進一步輸入第二階段十四分類架構進行疾病診斷。本階段旨在辨識影像中可能存在之 14 種疾病標籤，判斷其所包含之疾病類別。訓練過程僅採用包含疾病標籤之影像資料進行建模，以降低無病徵影像對資料分布造成之影響，減少類別不平衡問題，進而提升模型對病灶特徵之學習能力與分類效能。由於臨床實務中同一患者之胸腔 X 光影像可能同時呈現多種疾病特徵，例如同時具有肺炎（Pneumonia）與胸腔積液（Effusion）等病徵，因此本階段並非傳統單一類別多分類任務，而是屬於多標籤分類（Multi-label Classification）問題。

儘管單一 EfficientNet 十四分類架構已具備基礎之疾病辨識能力，但面對資料集中不同疾病樣本數量差異所形成之長尾分布問題，模型仍可能偏向學習樣本數較多之疾病特徵，使少數疾病類別（如疝氣或纖維化）的辨識能力受到限制。基於此，本研究進一步擴展十四分類架構，提出下一節所述之長尾分群分類架構，透過將疾病類別依據樣本分布進行分組，並建立對應之專家模型，以提升少數疾病類別之特徵學習能力與整體分類效能。

3.5.3 第二階段：長尾分群分類架構

NIH ChestX-ray14 資料集存在極端的類別不平衡現象，呈現出典型的長尾分佈（Long-tailed Distribution）。在此分佈下，占比多數的疾病類別（頭部類別）會主導模型訓練時的梯度更新，導致模型對樣本數量少的疾病類別（尾部類別）特徵學習不足，進而大幅降低罕見疾病的預測準確率。為了解決此長尾效應帶來的瓶頸，本研究設計了長尾分群分類架構。

本研究依據各疾病標籤在原始資料集中的樣本比例數量，設定 10% 作為分群閾值（Threshold）。研究將原先的 14 種疾病類別劃分為「頭部類別（Head Labels）」

與「尾部類別 (Tail Labels)」兩大群組。

- 第一群組為頭部類別 (訓練集樣本數比例 $\geq 10\%$): 包含資料集中樣本數最為常見的 3 種疾病, 分別為: 肺塌陷 (Atelectasis)、浸潤 (Infiltration) 與胸腔積液 (Effusion)。
- 第二群組為尾部類別 (樣本數比例 $< 10\%$): 為樣本數相對稀缺的剩餘 11 種疾病, 分別為: 疝氣 (Hernia)、心臟肥大 (Cardiomegaly)、實質化 (Consolidation)、腫塊 (Mass)、水腫 (Edema)、結節 (Nodule)、胸膜增厚 (Pleural_Thickening)、肺氣腫 (Emphysema)、肺炎 (Pneumonia)、纖維化 (Fibrosis) 與氣胸 (Pneumothorax)。

透過本研究所設計的長尾分群分類架構, 將頭部與尾部類別拆分至獨立的分類分支中進行特徵學習與預測。當模型針對單張醫學影像進行預測時, 這兩個獨立分支會分別計算並輸出對應疾病的預測機率; 隨後會將兩分支的機率輸出進行合併, 建構出最終完整的 14 項疾病預測結果。

透過此種分群方式, 希望能夠減少高樣本數量的類別在特徵學習上的主導情形, 使稀有類別也能被模型有效學習。

3.6 基於 EfficientNet 與 Swin Transformer 之交叉注意力特徵融合架構

本研究為了結合 EfficientNet 在局部空間特徵擷取上的優勢, 以及 Swin Transformer 在全局資訊的捕捉能力, 提出了一套基於交叉注意力機制 (Cross-Attention) 的深度學習網路架構。該架構主要由特徵擷取主幹、特徵投影、交叉注意力融合模組, 以及動態權重分類頭所組成, 具體架構如圖 3.4 所示。以下將詳細說明各模組之設計原因與運作方式。




圖 3.4 交叉注意力特徵融合架構圖

3.6.1 全局特徵提取轉換器：移動視窗轉換器（Swin Transformer）

Swin Transformer 的核心原理在於引入移動視窗自注意力機制(Shifted Window Self-Attention)，透過將影像特徵劃分為不同局部視窗，並僅在視窗內計算自注意力以降低計算成本，再藉由視窗位移操作建立不同區域間的資訊交流，使模型同時具備局部特徵提取能力與全局上下文關係建模能力。

本研究初期亦評估 ViT、DeiT 與 Swin Transformer 作為 Transformer 分支之特

徵提取架構。ViT 能透過全局自注意力機制有效學習影像區域間的關聯性，但其全局自注意力計算成本會隨影像區塊數量增加而提升，且缺乏階層式多尺度特徵學習能力，使其在需要同時辨識不同大小病灶特徵的醫學影像任務中存在限制。DeiT 雖透過知識蒸餾 (Knowledge Distillation) 技術降低 Transformer 對大規模資料集的依賴，使其更適合於有限資料條件下進行影像分類任務，但其仍延續 ViT 的架構設計，採用全局自注意力機制，並缺乏階層式多尺度特徵表示能力，因此在醫學影像分析中仍存在上述限制。相較之下，Swin Transformer 透過局部視窗注意力機制與階層式架構設計，能在降低自注意力運算成本的同時，逐步學習不同尺度的影像特徵，更符合胸腔 X 光影像中病灶大小差異明顯且分布複雜的特性。因此，本研究最終選用 Swin Transformer 作為 Transformer 分支的特徵提取網路，並於實作中透過 Python 的 timm (PyTorch Image Models) 函式庫載入具備預訓練權重的 swin_base_patch4_window12_384 模型。

3.6.2 基於 EfficientNet 與 Swin Transformer 之交叉注意力模型架構

研究架構使用預訓練並且已經使用 NIH 資料集訓練完的 EfficientNet-B5 作為 CNN 分支主幹網路，並選用同樣也訓練完的 Swin Transformer Base 作為 Transformer 分支主幹網路。

模型架構一開始給定輸入影像 x ，經過兩個主幹網路特徵提取之後，移除原始分類架構中的全局池化層 (Global Pooling)，以避免將空間位置特徵壓縮為單一全局表示。接著，將輸出的特徵圖展平 (Flatten) 並進行維度轉置，將空間位置轉換為序列形式之特徵表示，使後續交叉注意力機制能夠針對不同位置之局部與全局特徵進行交互學習，最終得到兩組序列特徵：

- EfficientNet 特徵 (F_{eff})：輸出維度為 $(B, N, 2048)$ ，其中 B 為批次大小， $N = 144$ 為特徵序列長度 (Token 數量)。
- Swin Transformer 特徵 (F_{swin})：輸出維度為 $(B, N, 1024)$ ，其中 B 為批次大小，

$N = 144$ 為特徵序列長度 (Token 數量)。

由於 CNN 與 Swin Transformer 輸出的特徵維度不同 (2048 與 1024)，為使其能進行注意力運算，所以加入了特徵投影層，將兩者統一降維至目標維度 $D = 1024$ 。投影層包含線性轉換 (Linear)、層正規化 (Layer Normalization) 以及 GELU 非線性啟動函數。其公式如下：

$$Q_{proj} = \text{GELU}(\text{LayerNorm}(F_{eff}W_q))$$

$$K_{proj} = V_{proj} = \text{GELU}(\text{LayerNorm}(F_{swin}W_{kv}))$$

其中， $W_q \in \mathbb{R}^{2048 \times 1024}$ 與 $W_{kv} \in \mathbb{R}^{1024 \times 1024}$ 為可學習之權重矩陣。由於 CNN 與 Transformer 的運算邏輯完全不同，兩者萃取出來的特徵數值大小 (Scale) 可能會有極大落差。因此，模型透過 Layer Normalization 將兩邊的數值拉回同一基準線，避免某一邊的特徵過度強勢而導致訓練不穩定；最後再加入 GELU 非線性函數，使模型能夠學習更複雜的非線性特徵關係，進一步提升疾病分類能力。

在完成特徵尺度統一後，本研究進一步探討不同特徵融合方式。傳統特徵融合方法如特徵拼接 (Concatenation) 雖能整合不同模型所擷取之特徵資訊，但僅透過特徵維度合併，無法主動學習不同特徵間的重要關聯性，且可能引入大量冗餘資訊。因此，本研究採用交叉注意力融合模組，以建立 CNN 與 Swin Transformer 特徵間之動態交互關係。該模組將 CNN 所提取之卷積特徵設定為查詢向量 (Query)，使模型能以局部病灶特徵為基準，主動向 Swin Transformer 所提供之全局特徵 (Key 與 Value) 進行比對與加權整合。透過此機制，模型能夠根據不同病灶區域的重要程度，自適應地尋找與局部異常特徵相關之胸腔全局資訊，進一步提升特徵融合能力。

為保留特徵序列間的空間關係，本研究引入可學習的位置編碼 (Positional Encoding) $PE \in \mathbb{R}^{1 \times N \times D}$ 並將其加至查詢 (Query) 與鍵 (Key) 向量中：

$$Q = Q_{proj} + PE$$

$$K = K_{proj} + PE$$

$$V = V_{proj}$$

位置編碼採用截斷常態分佈（Truncated Normal Distribution）進行初始化。一般標準的常態分佈雖然數值大多集中在平均值附近，但理論上仍可能隨機產生極大或極小的離群值；而「截斷」常態分佈則是在此基礎上強制設定了安全邊界。因此，此初始化方法在採樣時，會自動捨棄超出指定標準差範圍的極端值並重新採樣。這能有效避免權重過大所導致的訓練梯度不穩定，從而確保模型在捕捉序列順序特徵時，具備更好的穩定性。

在注意力運算機制上，融合模組包含 8 個注意力頭（Num Heads = 8）並加入丟棄率（Dropout）為 0.1 以防止過擬合。計算出多頭交叉注意力輸出後，透過殘差連接（Residual Connection）將原始查詢向量（Query）與該注意力輸出直接相加，再進行層正規化（Layer Normalization）。加入殘差連接目的是為了解決深層網路中常見的梯度消失問題（Vanishing Gradient Problem）。當網路層數較深時，誤差會在反向傳播過程中容易因連續相乘而趨近於零；透過殘差連接的直接相加，梯度可以繞過複雜層回傳，確保深層網路的參數能有效更新並穩定收斂。

$$\text{Attn_Out} = \text{MultiHeadAttention}(Q, K, V)$$

$$Z_1 = \text{LayerNorm}_1(Q_{proj} + \text{Attn_Out})$$

在完成交叉注意力運算後，為了進一步整合特徵，模組後方連接了一個前饋神經網路（FFN）。此 FFN 首先將維度擴展四倍（ $D \times 4$ ），目的是透過增加神經元數量，來提升模型對影像特徵的學習容量（Capacity），使其能更精細地捕捉各類病徵的細微差異。在擴展維度並經過 GELU 啟動函數與 Dropout 處理後，隨即將特徵維度壓縮回原大小。透過先升維再降維的結構設計，模型能在中間隱藏層中建立更豐富的特徵組合方式，進一步提升不同病灶特徵之間的區分能力，並在壓縮過程中去除部分冗餘特徵。

最後，加上一次殘差連接與層正規化（Layer Normalization）以確保訓練過程中梯度能穩定傳遞。經過上述步驟，即可取得融合 CNN 局部細節與 Swin 全局特

徵之最終輸出， $Z_2 \in \mathbb{R}^{B \times N \times 1024}$ ，即為融合 CNN 與 Transformer 特徵優勢之最終注意力特徵，取得融合後的特徵表示：

$$Z_2 = \text{LayerNorm}_2(Z_1 + \text{FFN}(Z_1))$$

為產生最終之類別預測（設定為 15 類），本研究首先對 F_{eff} 、 F_{swin} 及 Z_2 三組特徵進行全局平均池化（Global Average Pooling, GAP），將特徵壓縮至一維。隨後，分別通過具備 Dropout（率為 0.3）的獨立線性分類器，得到三組預測對數機率（Logits）：

$$\text{Logits}_{eff} = \text{Linear}_{eff}(\text{Dropout}(\text{GAP}(F_{eff})))$$

$$\text{Logits}_{swin} = \text{Linear}_{swin}(\text{Dropout}(\text{GAP}(F_{swin})))$$

$$\text{Logits}_{attn} = \text{Linear}_{attn}(\text{Dropout}(\text{GAP}(Z_2)))$$

在最終輸出階段，架構使用特徵融合（Feature Fusion）與集成學習（Ensemble Learning）方法，皆為提升模型泛化能力與分類效能的重要方法。常見的集成策略包含多數決、機率加權平均，以及透過額外分類器學習不同模型輸出的堆疊學習（Stacking）等方法。

在方法選擇上，Ashraf 等人在 NIH ChestX-ray14 資料集上比較多種集成方法，包含機率平均、XGBoost 堆疊學習，以及利用差分演化演算法最佳化模型權重之加權集成方法。實驗結果顯示，相較於其他集成策略，透過差分演化最佳化權重的集成模型具有較佳的分類效能（Ashraf, et al., 2023）。然而，差分演化主要是在模型訓練完成後，透過額外的搜尋程序尋找最佳權重組合，其權重最佳化過程與模型參數學習彼此分離。因此，本研究採用可學習權重機制，使權重能透過注意力融合模型訓練過程中的損失函數反向更新，根據資料特性自動調整各特徵分支對最終分類結果的貢獻比例。

綜合上述原因，本研究引入一組可學習之權重參數 $W_{learnable} \in \mathbb{R}^3$ （初始值設為 1/3）。透過 Softmax 函數確保權重總和為 1，使模型能在訓練過程中，自動學習評估不同特徵分支對最終決策之貢獻度：

$$[\alpha, \beta, \gamma] = \text{Softmax}(W_{\text{learnable}})$$

$$\text{Logits}_{\text{final}} = \alpha \cdot \text{Logits}_{\text{eff}} + \beta \cdot \text{Logits}_{\text{swin}} + \gamma \cdot \text{Logits}_{\text{attn}}$$

透過此機率加權融合機制，模型能在融合階段依據訓練資料自動調整局部特徵、全域特徵與交叉融合特徵的重要程度，相較於固定權重設定，可降低人工設定造成的偏差，並提升不同疾病影像分類時的適應能力。

綜合上述，本研究提出之交叉注意力特徵融合架構，透過 EfficientNet 與 Swin Transformer 兩種不同特徵擷取機制，分別學習胸腔 X 光影像中的局部病灶細節與全局空間關聯資訊。相較於單一模型僅依賴單一類型特徵表示，本架構藉由交叉注意力機制建立不同特徵間之動態交互關係，使模型能根據疾病特徵自適應地選擇重要資訊；同時結合可學習權重融合策略，使各分支模型之預測結果能依據資料特性進行最佳化整合。

3.7 實驗硬體設備與訓練參數設定

本研究之實驗硬體設備與模型訓練超參數設定如表 3.1 所示。為確保各模型架構皆能穩定學習胸腔 X 光之病理特徵並有效收斂，本研究統一設定模型訓練相關超參數。考量固定硬體環境下之顯示卡記憶體限制，後續訓練策略亦針對模型資源需求進行調整，以兼顧模型效能與訓練可行性。

實驗設備配置如下：中央處理器採用 Intel Core i7-14700F，顯示卡為 NVIDIA GeForce RTX 4060 (8GB VRAM)，系統記憶體為 16GB DDR5。

為確保各模型架構皆能穩定學習胸腔 X 光影像之病理特徵並有效收斂，本研究針對模型訓練參數進行統一設定，並依據顯示卡記憶體容量調整相關訓練策略，以兼顧模型效能與訓練可行性。在最佳化器 (Optimizer) 上採用 AdamW 演算法。AdamW 具備獨立的權重衰減機制，能更有效地抑制模型發生過擬合。整體初始學習率 (Learning Rate) 設定為 1×10^{-4} ，此一設定有助於在訓練骨幹網路時，確保模型能穩定收斂。此外，考量交叉注意力特徵融合模組包含額外初始化之可學習參

數，本研究在最佳化器 (Optimizer) 中，針對該部分參數設定了 1×10^{-3} 的權重衰減，以降低新增加參數造成過擬合之風險，提升模型於未知資料上的泛化能力。

在誤差評估方面，由於資料集中單張胸腔 X 光影像可能同時標註多種疾病標籤，屬於多標籤分類任務，本研究統一採用結合 Sigmoid 函數之二元交叉熵 (BCE With Logits Loss) 作為損失函數，使模型能針對各疾病類別獨立計算預測誤差。

由於本研究採用高解析度輸入影像 (384×384)，模型訓練過程對顯示卡記憶體需求較高，因此將單次批次大小 (Batch Size) 設定為 8。為提升梯度估計穩定性，本研究進一步導入梯度累積 (Gradient Accumulation) 機制，使模型累積 2 個迭代步數後再執行一次反向傳播 (Backpropagation) 與參數更新，以在有限硬體資源下模擬批次大小 16 之訓練效果。最後，為防止模型過度訓練造成過擬合，

最後，為避免模型過度訓練造成過擬合，本研究導入提早停止機制，並以驗證集之 F1-score 作為主要監控指標。當模型連續 3 個訓練週期 (Epochs) 未能提升驗證集 F1-score 時，即停止訓練流程，並保留驗證階段中 F1-score 表現最佳之模型權重，作為後續測試與推論使用之最終模型。

超參數 (Hyperparameter)與硬體設備	設定內容
輸入影像大小	384 x 384
最佳化器 (Optimizer)	AdamW
學習率 (Learning Rate)	1×10^{-4}
交叉注意力模型權重衰減	1×10^{-3}
實際批次大小 (Batch Size)	8
梯度累積步數 (Gradient Accumulation Steps)	2
損失函數 (Loss Function)	BCEWithLogitsLoss
中央處理器	i7-14700F
顯示卡	NVIDIA GeForce RTX 4060

	(8GB VRAM)
系統記憶體	16GB DDR5

表 3.1 實驗硬體設備與模型超參數設定



第四章 實驗結果與討論

4.1 實驗資料集

本研究採用由美國國家衛生研究院臨床中心（NIH Clinical Center）發佈的公開資料集 NIH ChestX-ray14 (Wang, et al., 2017)。該資料集是目前胸部 X 光研究領域最具代表性的數據集之一，其樣本來自 1992 年至 2015 年間的真實臨床案例。

本資料集總共包含 112,120 張 X 光影像，來自 30,805 位患者。在類別分佈上，資料集呈現顯著的類別不平衡現象，如圖 4.1 所示。例如樣本數最多的「無病徵(No Finding)」佔了全部樣本數超過一半的比例，而「浸潤」(Infiltration)與「積液」(Effusion)是樣本數較多的疾病標籤，「疝氣」(Hernia)或「肺炎」(Pneumonia)的樣本相對稀少很多。資料集類別不平衡現象也是訓練過程中需克服的主要挑戰之一。




圖 4.1 NIH 資料集分布圖

為使後續章節的圖表標示與內文排版呈現更為便利，本研究針對資料集中的

十五項分類標籤制定了統一的簡寫規則。各標籤之簡寫皆由三個大寫英文字母組成，其簡寫邏輯為：擷取原始英文類別名稱之「前兩個英文字母」與「最後一個英文字母」組合而成。舉例而言，「疝氣 (Hernia)」取前兩碼「He」與字尾「a」組成「HEA」；「無異常發現 (No Finding)」則取前兩碼「No」與字尾「g」組成「NOG」；若遇底線分隔之複合詞如「胸膜增厚 (Pleural_Thickening)」，也是以首詞前兩碼「Pl」與尾詞字尾「g」組成「PLG」。十五項類別之中文名稱、完整英文標籤及對應簡寫對照，統一整理如表 4.1 所示。

中文名稱	英文標籤	標籤簡寫
肺不張	Atelectasis	ATS
疝氣	Hernia	HEA
心臟肥大	Cardiomegaly	CAY
浸潤	Infiltration	INN
實變	Consolidation	CON
腫塊	Mass	MAS
水腫	Edema	EDA
結節	Nodule	NOE
積液	Effusion	EFN
胸膜增厚	Pleural_Thickening	PLG
肺氣腫	Emphysema	EMA
肺炎	Pneumonia	PNA
纖維化	Fibrosis	FIS
氣胸	Pneumothorax	PNX
無病徵	No Finding	NOG

表 4.1 疾病中文名稱、完整英文標籤簡寫對照表

4.2 評估方法

在影像分類任務中，混淆矩陣 (Confusion Matrix) 是評估模型預測表現常使用的方法。如表 4.2 所示，混淆矩陣由四種數值組成，分別為真正例 (True Positive, TP)、真負例 (True Negative, TN)、假正例 (False Positive, FP) 以及假負例 (False Negative, FN)。本研究使用混淆矩陣所計算之評估指標，包括精確率 (Precision)、靈敏度 (Sensitivity)、特異度 (Specificity)、F1-score 與曲線下面積 (Area Under Curve, AUC)，以分析模型在不同類別上的分類能力。由於本研究資料集存在類別分布不平衡問題，因此相較於僅使用準確率 (Accuracy)，上述指標能更完整反映模型於少數類別與整體分類任務中的實際效能。

	預測 Positive	預測 Negative
實際 Positive	真正例 TP (True Positive)	假負例 FN (False Negative)
實際 Negative	假正例 FP (False Positive)	真負例 TN (True Negative)

表 4.2 混淆矩陣

4.2.1 精確率 (Precision)

精確率用於衡量模型所有預測為正例的樣本中，實際為正例的比例，如公式 4.1 所示。在本研究中，精確率代表模型判定為胸腔疾病影像時，實際確實具有該疾病的機率，可反映模型降低誤診 (False Positive) 的能力。

$$Precision = \frac{TP \text{ (True Positive)}}{TP \text{ (True Positive)} + FP \text{ (False Positive)}}$$

公式 4.1 精確率

4.2.2 靈敏度 (Sensitivity)

靈敏度又稱為召回率 (Recall)，用於衡量所有實際為正例的樣本中，被模型成

功辨識出的比例，如公式 4.2 所示。在胸腔 X 光疾病分類中，靈敏度表示所有實際患有疾病的影像中，有多少成功被模型預測為有疾病。

在醫療影像應用中，靈敏度為相當重要之評估指標。若模型靈敏度過低，代表實際患病個案誤判為正常，進而增加漏診風險。因此，高靈敏度模型通常較適合作為臨床輔助篩檢工具。

$$\text{Sensitivity} = \frac{TP \text{ (True Positive)}}{TP \text{ (True Positive)} + FN \text{ (False Negative)}}$$

公式 4.2 靈敏度

4.2.3 特異度 (Specificity)

特異度 (Specificity) 用於衡量所有實際為負例的樣本中，被模型正確判斷為負例的比例，如公式 4.3 所示。在本研究中，特異度表示所有正常胸腔 X 光影像中，被模型正確分類為正常的能力。

特異度可反映模型降低誤報 (False Positive) 的能力。若特異度過低，代表模型容易將正常影像誤判為患有疾病，可能造成不必要的進一步檢查與醫療資源浪費。

$$\text{Specificity} = \frac{TN \text{ (True Negative)}}{TN \text{ (True Negative)} + FP \text{ (False Positive)}}$$

公式 4.3 特異度

4.2.4 F1-score

F1-score 為精確率 (Precision) 與靈敏度 (Sensitivity) 的調和平均數，能同時考量精確率與靈敏度之間的平衡。當模型同時具有較高精確率與靈敏度時，F1-score 才會獲得較高數值。因此，該指標可更全面評估模型在疾病檢測上的整體表現，如公式 4.4 所示。

$$F1 - Score = \frac{2}{\frac{1}{Precision} + \frac{1}{Sensitivity}} = \frac{2 \times Precision \times Sensitivity}{Precision + Sensitivity}$$

公式 4.4 F1-Score

4.2.5 曲線下面積 (AUC)

曲線下面積 (Area Under the Curve, AUC) 為 ROC 曲線 (Receiver Operating Characteristic Curve) 下的面積，用於衡量分類模型在不同閾值下的模型辨識能力。ROC 曲線主要以假正例率 (False Positive Rate) 作為橫軸，真正例率 (True Positive Rate) 作為縱軸進行繪製。

在胸腔 X 光疾病分類任務中，曲線下面積可反映模型區分影像的能力。當曲線下面積值越接近 1 時，表示模型具有較佳的分類能力；若曲線下面積接近 0.5，則代表模型分類效果接近隨機猜測。曲線下面積能全面評估模型於不同分類門檻下之穩定性與泛化能力，因此廣泛應用於醫療影像分析研究中。

$$FPR = \frac{FP}{FP + TN}, \quad TPR = \frac{TP}{FP + TN}$$

$$AUC = \int_0^1 TPR(FPR) d(FPR)$$

公式 4.5 曲線下面積

4.3 資料增強與上採樣策略結果分析

本研究針對 NIH ChestX-ray14 資料集極端的類別不平衡問題，提出了結合隨機影像變換的資料增強 (Data Augmentation) 與提升少數類別數量的資料上採樣 (Oversampling) 策略。本節將具體展示上採樣後的數據分佈情形，並透過實驗數據驗證這些策略對模型整體分類效能與泛化能力的實際影響。

4.3.1 資料上採樣後分布

為了具體呈現資料上採樣策略對類別不平衡現象的影響，各階段上採樣後實際的樣本數值與比例，記錄於表 4.3 中。並透過圖 4.2 展示訓練集在不同上採樣門檻 (0、1000、2000、3000、4000 筆) 下，各類別佔整體資料集比例的變化趨勢。

疾病標籤	原始 訓練集	上採樣至 1000 筆	上採樣至 2000 筆	上採樣至 3000 筆	上採樣至 4000 筆
ATS	8077 (10.37%)	8187 (10.4%)	8669 (10.55%)	9376 (10.73%)	10097 (10.9%)
HEA	151 (0.19%)	1000 (1.27%)	2070 (2.52%)	3179 (3.64%)	4244 (4.58%)
CAY	1922 (2.47%)	1945 (2.47%)	2078 (2.53%)	3154 (3.61%)	4217 (4.55%)
INN	13909 (17.86%)	14027 (17.81%)	14932 (18.18%)	16285 (18.63%)	17694 (19.1%)
CON	3246 (4.17%)	3264 (4.15%)	3459 (4.21%)	3729 (4.27%)	4185 (4.52%)
MAS	3865 (4.96%)	4006 (5.09%)	4322 (5.26%)	4797 (5.49%)	5327 (5.75%)
EDA	1592 (2.04%)	1593 (2.02%)	2279 (2.77%)	3316 (3.79%)	4307 (4.65%)
NOE	4383 (5.63%)	4408 (5.6%)	4580 (5.58%)	4875 (5.58%)	5188 (5.6%)
EFN	9094 (11.68%)	9174 (11.65%)	9669 (11.77%)	10706 (12.25%)	11807 (12.74%)
PLG	2414 (3.1%)	2444 (3.1%)	2628 (3.2%)	3235 (3.7%)	4260 (4.6%)
EMA	1669 (2.14%)	1688 (2.14%)	2047 (2.49%)	3082 (3.53%)	4089 (4.41%)
PNA	994 (1.28%)	1004 (1.28%)	2011 (2.45%)	3020 (3.46%)	4019 (4.34%)
FIS	1174 (1.51%)	1202 (1.53%)	2000 (2.44%)	3000 (3.43%)	4000 (4.32%)
PNX	3698 (4.75%)	3734 (4.74%)	3929 (4.78%)	4329 (4.95%)	4699 (5.07%)
NOG	42036 (53.97%)	42036 (53.39%)	42036 (51.18%)	42036 (48.1%)	42036 (45.37%)
總數	77889	78738	82132	87397	92652

表 4.3 各類別上採樣後實際的樣本數與比例

而觀察下圖 4.2 的整體趨勢，在圖最上方的綠色無病徵（No Findings）曲線，

在原始資料中佔據了超過 50%的極高比例。隨著對少數疾病類別進行漸進式上採樣，無異常類別的相對佔比呈現平緩下降的趨勢，但即便上採樣門檻達到最高的 4000 筆時，其比例依然維持在 45%左右。此種大規模不平衡狀態，難以僅透過對少數類別的上採樣來完全改善。

若將焦點轉向代表疾病的 14 種標籤，可以發現其分佈呈現出極為明顯的斷層與長尾 (Long-tail) 現象。在圖表中段，浸潤 (Infiltration)、胸腔積液 (Effusion) 與肺塌陷 (Atelectasis) 這 3 類別的佔比明顯高於其他疾病，形成了一個獨立的群集，這 3 類別同時也是後續長尾分群的頭部模型類別。

相對地，圖表最下方緊密糾結的 11 條折線 (如疝氣、肺炎、纖維化等)，在未經上採樣前，其佔比極低，都在 0%至 6%的狹窄區間內，其中部分罕見疾病的起始佔比甚至趨近於零。隨著上採樣門檻的逐步提升，可以觀察到這 11 個尾部類別的佔比折線呈現緩步微幅上升，最終於 4000 筆的門檻時，整體大致約為 4%至 6%的區間內，這 11 類別同時也是後續長尾分群的頭部模型類別

特別需要說明的是，由於本資料集屬於多標籤 (Multi-label) 資料，同一張 X 光影像可能同時標註了多種併發疾病。因此，當針對少數類別的影像進行資料上採樣時，該影像可能同時伴隨著其他疾病的標籤，便會連帶增加其他類別的樣本數量。




圖 4.2 各類別疾病經過上採樣後的比例變化

4.3.2 資料增強和上採樣成效分析

為解決 NIH ChestX-ray14 資料集中嚴重的類別不平衡與特徵多樣性不足的問題，本研究分別導入了資料增強(Data Augmentation)與資料上採樣(Oversampling)策略，並評估其對模型整體與各別類別效能的影響。表 4.4 總結了 EfficientNet 模型在不同資料處理階段下的各項總體評估指標表現。

	F1-score	Precision	Sensitivity	Specificity	AUC
原始資料集	0.3718	0.3209	0.4674	0.9052	0.8377
資料增強後	0.3794	0.3367	0.4630	0.9124	0.8405
上採樣至 1000 筆	0.3820	0.3290	0.4727	0.9124	0.8395
上採樣至 2000 筆	0.3608	0.3112	0.4494	0.9181	0.8335
上採樣至 3000 筆	0.3592	0.3082	0.4621	0.9117	0.8318
上採樣至 4000 筆	0.3596	0.3106	0.4533	0.9122	0.8277

表 4.4 不同的資料增強和上採樣方法平均分數比較

如表 4.4 所示，在引入隨機旋轉、平移、亮度與對比度調整等資料增強策略後，模型的總體 F1-score 由 0.3718 提升至 0.3794，Precision 與 AUC 亦分別提升至

0.3367 與 0.8405。此結果表示，藉由模擬 X 光拍攝時可能產生的旋轉、位移等變化，能使模型的辨識能力微幅提升。隨後，本研究針對少數類別進行資料上採樣。當設定各類別最低樣本數為 1000 筆時，總體 F1-score 達到最高點 0.3820，Sensitivity 也來到 0.4727 的最佳表現。然而，當進一步將上採樣目標提升至 2000、3000 與 4000 筆時，整體的 F1-score 與 AUC 卻呈現逐階下滑的趨勢，這顯示過度依賴過採樣反而會引發模型效能的衰退。

進一步探究上採樣階段的細部表現，在「上採樣至 1000 筆」的設定下，實際上僅有疝氣（Hernia，原始 151 筆）與肺炎（Pneumonia，原始 994 筆）的樣本數低於此樣本數量，因此只有這兩個類別受到了實質的資料上採樣影響。從實驗結果來看，F1-score 變化最大且最顯著的正是上採樣比例最高的疝氣（Hernia），如表 4.5 所示，其預測效能在上採樣至 1000 筆時達到 0.4754 的高峰，出現了大幅度的提升；然而，當上採樣數量進一步提升至 2000 筆以上時，因原始樣本過少、特徵多樣性不足，使模型過度學習疝氣樣本的特定影像特徵，導致模型產生嚴重的過擬合（Overfitting）現象，使疝氣（Hernia）的 F1-score 隨即大幅崩跌至 0.2876。

	F1-score	Precision	Sensitivity	Specificity	AUC
原始資料集	0.3818	0.3962	0.3684	0.9986	0.9336
資料增強後	0.4400	0.5116	0.3860	0.9991	0.9312
上採樣至 1000 筆	0.4754	0.4462	0.5088	0.9985	0.9379
上採樣至 2000 筆	0.2876	0.2292	0.3860	0.9968	0.9410
上採樣至 3000 筆	0.3259	0.2821	0.3860	0.9976	0.9456
上採樣至 4000 筆	0.3407	0.2949	0.4035	0.9976	0.9112

表 4.5 不同的資料增強對疝氣（Hernia）類別的影響

另一方面，觀察原始數量僅有 994 筆的肺炎（Pneumonia）的表現，如表 4.6 所示，可以發現無論資料如何上採樣，其 F1-score 始終在 0.1 左右徘徊，變化幅度非常微小。這結果顯示，模型本身難以單憑現有架構或單純的重複抽樣，來有

效學習並萃取出肺炎的特徵。

	F1-score	Precision	Sensitivity	Specificity	AUC
原始資料集	0.1062	0.0626	0.3487	0.9309	0.7701
資料增強後	0.1083	0.0674	0.2763	0.9494	0.7845
上採樣至 1000 筆	0.1028	0.0643	0.2566	0.9506	0.7635
上採樣至 2000 筆	0.1038	0.0700	0.2007	0.9648	0.7711
上採樣至 3000 筆	0.0984	0.0631	0.2237	0.9561	0.7714
上採樣至 4000 筆	0.0972	0.0629	0.2138	0.9578	0.7670

表 4.6 不同的資料增強對肺炎（Pneumonia）類別的影響

研究發現「上採樣至 1000 筆」能在 F1-score 與 AUC 等各項評估指標上取得最佳的平衡。過度的資料上採樣不僅無法帶來持續的效益，反而會嚴重干擾多數類別的預測並導致模型效能崩潰。因此，在後續的所有模型架構訓練中，本研究皆統一採用「結合資料增強，並對極少數類別上採樣至 1000 筆」作為標準的資料處理策略，以確保模型評估的基準一致。

4.4 骨幹網路比較

本節旨在探討並比較單一骨幹網路在胸部 X 光多標籤分類任務上的表現。實驗分別選用基於注意力機制的 Swin Transformer，以及基於卷積網路的 EfficientNet 進行評估。透過檢視兩者的實驗數據，分析不同特徵擷取機制在處理複雜醫學影像時的優勢與局限。

實驗結果如表 4.7 所示，EfficientNet 在多數核心指標上展現出相對優勢。其平均 F1-score 為 0.3820、Sensitivity 為 0.4727、AUC 為 0.8395，皆微幅領先 Swin Transformer 的 0.3627、0.4402 與 0.8307。這顯示 EfficientNet 憑藉其局部特徵擷取能力與卷積神經網路固有的局部歸納偏置（Local Inductive Bias），在整體病徵的預測上具備較好的表現。反之，Swin Transformer 雖在大部分指標上略遜一籌，但其

Specificity 高達 0.9193，微幅領先 EfficientNet 的 0.9124，反映出全局注意力機制在抑制 False Positive 方面具備一定實力。

	F1-score	Precision	Sensitivity	Specificity	AUC
SwinTransformer	0.3627	0.3179	0.4402	0.9193	0.8307
EfficientNet	0.3820	0.3290	0.4727	0.9124	0.8395

表 4.7 EfficientNet 和 Swin Transformer 平均分數比較

細看兩者模型各個類別的比較數據，如表 4.8 所示，兩種網路架構在胸腔 X 光影像的多標籤分類任務中，展現出不同的效能差異。整體而言，EfficientNet 在 15 個疾病類別中，共有 11 個類別的 F1-score 優於 Swin Transformer，顯示出卷積神經網路（CNN）在此類醫學影像任務中還是具備強大的優勢。

進一步分析不同疾病類別之分類結果，可以發現 Swin Transformer 與 EfficientNet 在各項評估指標上呈現互補特性。由表 4.8 可觀察到，僅有 3 個疾病類別是單一模型在五項指標中全面優於另一模型，其中 EfficientNet 於 2 個類別中全面優於 Swin Transformer，而 Swin Transformer 於 1 個類別中展現全面優勢。然而，其餘 11 個疾病類別則呈現不同指標間的交錯表現，顯示兩種模型在不同疾病特徵的擷取與判斷上各具優勢。

標籤	模型名稱	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	Swin Transformer	0.4027	0.3398	0.4939	0.8900	0.8113
	EfficientNet	0.4171	0.3404	0.5386	0.8803	0.8158
HEA	Swin Transformer	0.3673	0.3000	0.4737	0.9973	0.9179
	EfficientNet	0.4754	0.4462	0.5088	0.9985	0.9379
CAY	Swin Transformer	0.3387	0.3246	0.3541	0.9807	0.9011
	EfficientNet	0.3783	0.3501	0.4115	0.9800	0.9108
INN	Swin Transformer	0.4164	0.3682	0.4789	0.8193	0.7116

	EfficientNet	0.4154	0.3197	0.5930	0.7224	0.7194
CON	Swin Transformer	0.2268	0.1590	0.3952	0.9065	0.8075
	EfficientNet	0.2310	0.1749	0.3400	0.9283	0.8064
MAS	Swin Transformer	0.3963	0.3713	0.4250	0.9586	0.8433
	EfficientNet	0.4088	0.3509	0.4897	0.9479	0.8492
EDA	Swin Transformer	0.2883	0.2156	0.4352	0.9624	0.8984
	EfficientNet	0.2794	0.1997	0.4648	0.9558	0.8970
NOE	Swin Transformer	0.3114	0.2858	0.3419	0.9487	0.7639
	EfficientNet	0.3555	0.3511	0.3601	0.9600	0.7936
EFN	Swin Transformer	0.5456	0.4840	0.6252	0.9063	0.8799
	EfficientNet	0.5444	0.4823	0.6249	0.9057	0.8798
PLG	Swin Transformer	0.2181	0.1614	0.3365	0.9509	0.8002
	EfficientNet	0.2177	0.1693	0.3050	0.9580	0.8026
EMA	Swin Transformer	0.4933	0.4763	0.5115	0.9849	0.9219
	EfficientNet	0.5134	0.4333	0.6299	0.9779	0.9329
PNA	Swin Transformer	0.0954	0.0604	0.2270	0.9533	0.7625
	EfficientNet	0.1028	0.0643	0.2566	0.9506	0.7635
FIS	Swin Transformer	0.1682	0.1757	0.1613	0.9888	0.7890
	EfficientNet	0.1846	0.1534	0.2317	0.9810	0.8101
PNX	Swin Transformer	0.4234	0.3530	0.5286	0.9496	0.8739
	EfficientNet	0.4538	0.4102	0.5078	0.9620	0.8908
NOG	Swin Transformer	0.7488	0.6930	0.8145	0.5926	0.7788

	EfficientNet	0.7521	0.6890	0.8280	0.5780	0.7833
--	--------------	---------------	--------	---------------	--------	---------------

表 4.8 EfficientNet 和 Swin Transformer 各標籤分數比較

綜合上述分析，EfficientNet 在大部分的指標中皆勝過 Swin Transformer，但 Swin Transformer 整體 Specificity 小幅贏過 EfficientNet。而細看各個疾病表現，兩者表現也並不是單一模型全面優於另一模型的情況，而是在不同疾病類別於不同的評估指標上展現各自優勢。透過結合兩者所擷取之局部細節特徵與全局關聯資訊，有望彌補單一模型在特定病徵辨識上的弱勢，進一步提升分類效能。

4.5 二階段分類架構成效分析

本節將針對本研究所提出的二階段分類架構進行成效評估。在處理複雜的醫學影像分類任務時，直接進行多類別分類往往會面臨資料不平衡的挑戰。為此，本研究採用以 EfficientNet 為骨幹網路的二階段架構：第一階段先進行二分類任務，判斷影像是否有無病徵（Finding or No Finding）；第二階段則針對被判定為有病徵的影像，進一步進行十四分類或長尾分群分類任務（Long-Tail Classification）。透過此策略，期望能先有效過濾正常影像，再讓模型專注於病徵特徵的細部分類，已減經類別不平衡帶來的影響。以下將依序分析各階段的實驗結果與模型表現。

4.5.1 第一階段二分類成效分析

第一階段的分類任務旨在區分輸入影像是否具有病徵（Finding）。此階段作為後續細部分類的前置過濾模型，其表現直接影響整體系統的準確性，第一階段二分類模型的評估指標結果如表 4.9 所示。

標籤	F1-score	Precision	Sensitivity	Specificity	AUC
Finding	0.7145	0.6269	0.8306	0.5622	0.7725

表 4.9 二分類模型預測 Finding 的各個指標分數

觀察表 4.9 的數據得知，模型在 F1-score 上取得了 0.7145 的成績，AUC 則為 0.7725。其中，模型在 Sensitivity 的表現最為突出，達到 0.8306，代表模型能夠成

功辨識出約 83%的實際為有病徵的案例，有效降低「有病卻被誤判為沒病」的漏診風險，確保大部分存在病徵的影像都能夠被送入後續的分類階段，並顯示了模型具有一定的條件能作為前置過濾的模型。然而，模型在 Specificity 上的表現為 0.5622，表示約有 44%的無病徵影像被判為有病徵，進而被錯誤的送入第二階段進行疾病分類。此現象也增加了後續分類的負擔，使第二階段需處理更多誤判影像。

4.5.2 第二階段十四分類架構成效分析

在第一階段二分類模型初步過濾影像後，第二階段十四分類模型的目標是針對被判定為有病徵 (Finding) 的影像，進一步辨識出具體的疾病類別。

單獨檢視僅包含十四種疾病資料的模型表現。相關數據比較如表 4.10 所示。實驗數據顯示，排除無病徵 (No Finding) 影像後，單獨十四分類模型的平均 F1-score 為 0.4426、Precision 為 0.3948、Sensitivity 為 0.5319；相較於原始 EfficientNet 模型在排除無病徵標籤後的平均表現 (F1-score 為 0.3555、Precision 為 0.3033、Sensitivity 為 0.4473)，這三項指標皆有顯著的成長。此結果初步說明，將佔比極大的正常影像獨立至第一階段處理，能有效減輕類別不平衡的壓力，使第二階段模型得以更專注於學習並區分各項病徵的特徵。

然而，觀察指標也可發現，單獨十四分類模型的整體辨識能力 (AUC) 為 0.8208，略低於原始模型排除正常標籤後的 0.8436，且 Specificity 亦有所下降 (由 0.9363 降至 0.8768)。其主要原因在於，模型中各疾病標籤彼此為獨立學習任務，在原始設定下，由於 No Finding 樣本數佔比極高，使得資料集中各個疾病標籤「沒有疾病 (label=0)」的情況多於「存在這個疾病 (label=1)」的情況，因此模型在學習過程中會逐漸傾向預測為 0 以降低整體損失。此種偏向使得模型在多數疾病標籤上可以偏向預測為 0 而取得較高的表現。當資料集移除 No Finding 樣本後，各疾病標籤的正負樣本比例趨於平衡，使模型無法再依賴大量預測為 0 來提升表現，使得 Specificity 和 AUC 有所下降。

模型	F1-score	Precision	Sensitivity	Specificity	AUC
原始模型排除 掉 NOG 之平均	0.3555	0.3033	0.4473	0.9363	0.8436
14 分類模型	0.4426	0.3948	0.5319	0.8768	0.8208

表 4.10 14 分類與原始模型排除 No Finding 後各指標平均分數

接著，本研究將第一階段與第二階段進行串接，完成完整之二階段十四分類架構，並與原始 EfficientNet 模型之平均分數進行比較，如表 4.11 所示。實驗結果顯示，完整之二階段架構 F1-score、Precision、Sensitivity 與 AUC 皆有所下降，其主要原因在於串聯式架構存在「誤差向下傳遞」現象。當第一階段之二分類模型將無病徵影像誤判為有病徵時，這些影像將被強制送入第二階段，使十四分類模型必須對本質上為有病徵的影像進行疾病分類，導致誤差產生，進而拉低整體分數。

另一方面，本研究之二階段分類架構於最終評估時，將輸出結果重新歸類回十五類別。而由於第一階段對有病徵具有較高辨識能力，使多數具病徵之影像能被有效保留並送入第二階段。此種有效抓到異常影像的成果，進而使 No Finding 標籤的 Specificity 大幅提升，也使得模型的 Specificity 平均值有所上升。

模型	F1-score	Precision	Sensitivity	Specificity	AUC
原始 EfficientNet	0.3820	0.3290	0.4727	0.9124	0.8395
第一階段二分類 結合 14 分類	0.3482	0.3210	0.4189	0.9242	0.7845

表 4.11 原始模型和第一階段二分類結合 14 分類模型架構各指標平均分數

綜合上述實驗結果，雖然二階段分類架構 Specificity 有所提升，但將兩者串聯為完整系統時，第一階段產生的誤差會被傳遞至後續分類流程，進而降低了整體的分類效能，顯示此二階段架構受限於第一階段所帶來的誤差累積。

4.5.3 第二階段長尾分群分類架構成效分析

為進一步解決十四種疾病中存在的嚴重資料不平衡問題，本研究在第二階段

導入了長尾分群分類架構 (Long-Tail Classification)，將資料量較大的三種疾病 (Atelectasis、Infiltration、Effusion) 歸類為頭部 (Head) 群組，其餘十一種較罕見的疾病歸類為尾部 (Tail) 群組，並分別訓練各自的分類模型。

首先，單獨檢視頭部與尾部獨立模型的表現，如表 4.12 所示。在頭部 (Head) 群組方面，獨立模型的平均 F1-score 為 0.6871、Sensitivity 為 0.8104，相較於原始模型在相同類別上的表現 (F1-score 為 0.4590、Sensitivity 為 0.5855)，出現了顯著的提升。在尾部 (Tail) 群組方面，尾部模型的平均 F1-score 為 0.4907、Sensitivity 為 0.5562，同樣大幅優於原始模型在尾部類別上的表現 (F1-score 為 0.3273、Sensitivity 為 0.4096)。此結果證實，透過長尾分群策略將資料量懸殊的疾病分開訓練，能有效避免多數類別主導梯度更新，使得模型在面對罕見疾病時，依然能保留並捕捉其微弱的病徵特徵。

模型	F1-score	Precision	Sensitivity	Specificity	AUC
原始模型的頭部類別	0.4590	0.3808	0.5855	0.8361	0.8050
頭部模型	0.6871	0.5967	0.8104	0.5991	0.7931
原始模型的尾部類別	0.3273	0.2821	0.4096	0.9636	0.8541
尾部模型	0.4907	0.4680	0.5562	0.8910	0.8354

表 4.12 原始模型頭尾類別與單獨頭尾模型平均分數

接著，本研究將第一階段的二分類模型，以及頭部與尾部分類模型進行完整串聯，評估「二階段長尾分群架構」的整體成效。如表 4.13 所示，串聯後的架構平均 F1-score 為 0.3431、Sensitivity 為 0.4258、AUC 為 0.7801。相較於原始模型的平均表現 (F1-score 為 0.3820、Sensitivity 為 0.4727、AUC 為 0.8395)，完整架構在各項主要指標上皆呈現下滑，僅 Specificity (0.9159) 微幅優於原始模型 (0.9124)。

模型	F1-score	Precision	Sensitivity	Specificity	AUC
原始 EfficientNet	0.3820	0.3290	0.4727	0.9124	0.8395

第一階段二分類 結合長尾模型	0.3431	0.3074	0.4258	0.9159	0.7801
-------------------	--------	--------	--------	---------------	--------

表 4.13 原始模型和第一階段二分類結合長尾分類模型架構各指標平均分數

深入探究其整體表現不升反降的原因，在於此模型架構面臨了更為嚴重的「雙重誤差傳遞」問題。第一層誤差來自第一階段的二分類模型，被錯誤預測為有病徵的影像會被送入第二階段；第二層誤差則來自於頭尾機制，在將頭部模型與尾部模型之輸出進行直接加總融合時，使得錯誤預測在融合過程中被放大。

另一方面，Specificity 提升的原因也與二階段 14 分類相同，模型第一階段對有病徵有較高辨識能力，進而讓 No Finding 標籤的 Specificity 大幅提升，也使得模型的 Specificity 平均值有所上升。

4.5.4 二階段分類架構綜合總結

總結本節 4.5 之實驗結果，本研究所提出的分階與分群架構在「獨立任務」上皆展現了極佳的成效。第一階段的二分類模型能維持高 Sensitivity，第二階段排除正常影像後的十四分類模型、頭部分類模型與尾部分類模型，在 F1-score 與 Sensitivity 上皆顯著優於單一的原始 EfficientNet 模型。這充分證實了「分開有無病徵影像」以及「切分長尾分佈資料」的核心概念，確實能有效引導模型專注於學習罕見疾病標籤的特徵。

然而，當這些獨立模型被串聯起來時，系統表現因為第一階段的誤差向下傳遞。第一階段對於無病徵的誤判與第二階段的預測錯誤相互疊加，導致整體系統的 F1-score 與 Sensitivity 不如直接進行十五分類的原始模型。

此結論為後續醫學影像多標籤分類研究提供了參考：雖然針對資料不平衡進行切分訓練能提升局部特徵的捕捉能力，但直接進行串聯架構具備限制。未來的研究方向可能需要考慮採用其他決策方式，在保留分群優勢的同時，避免串聯決策擴大誤差累積。

4.6 基於 EfficientNet 與 Swin Transformer 交叉注意力特徵

融合架構分析

為驗證本研究所提出之「交叉注意力特徵融合模組」中，各項網路結構設計的必要性與實質貢獻，本節針對該模組的核心組件進行了消融實驗(Ablation Study)。實驗採用控制變因之方式，逐步添加特定網路元件，藉此評估其對模型整體分類效能的影響，並確保本研究所設計之融合架構並非無效的堆疊。

4.6.1 Residual Connection 之影響

在深度神經網路的設計中，殘差連接(Residual Connection)常被用來緩解深層網路中的梯度消失問題，並確保原始特徵在經過複雜的非線性轉換後不會遺失。如本研究的特徵融合架構圖(圖 3.4)中紅色箭頭路徑所示，本研究在多頭注意力機制(Multi-head Attention)的輸出端，以及後續的前饋神經網路(Linear-GELU-Linear)輸出端，皆加入了殘差連接設計。為驗證此設計的必要性，本實驗比較了「僅使用交叉注意力」與「加上殘差連接」的效能差異，具體成效如表 4.14 所示。

	F1-score	Precision	Sensitivity	Specificity	AUC
加入殘差連接前	0.3781	0.3257	0.4778	0.9095	0.8267
加入殘差連接後	0.3871	0.3325	0.4886	0.9111	0.8402

表 4.14 交叉注意力架構導入殘差連接後之平均分數

觀察表 4.14 的實驗數據發現，在尚未加入殘差連接前，交叉注意力融合模組的 F1-score 為 0.3781、Sensitivity 為 0.4778、AUC 為 0.8267。當引入殘差連接後，所有評估指標皆呈現了微幅成長。其中，F1-score 提升至 0.3871，Sensitivity 提升至 0.4886，而 AUC 則成長至 0.8402。

此種結果的原因在於，在模型架構中的交叉注意力機制中，查詢向量(Query)來自 EfficientNet 提取的局部卷積特徵，而鍵向量(Key)與值向量(Value)則來自 Swin Transformer 的全局注意力特徵。若缺乏殘差連接，EfficientNet 的局部特徵

在經過注意力矩陣的點積與加權運算後，不僅容易產生梯度消失，更會導致原始的特徵被覆蓋，進而遺失重要的資訊。

透過加入殘差連結，模型得以將 EfficientNet 最原始的局部卷積特徵直接「加疊」到交叉注意力的輸出上。保障了梯度在反向傳播時的穩定性，更使得模組在整合 Swin Transformer 全局特徵的同時，能有效保留 EfficientNet 對局部細節的敏銳度。結果也證實了殘差連接在本融合架構中具有正面效益，是確保模型訓練更加穩定的網路組件。

4.6.2 Positional Embedding 之影響

本節進一步針對「位置嵌入 (Positional Embedding)」模組進行消融實驗分析。該模組的設計目的在於將空間資訊重新加入特徵之中，使模型能夠辨識特徵的位置。結果如表 4.15 所示。

	F1-score	Precision	Sensitivity	Specificity	AUC
加入位置嵌入前	0.3871	0.3325	0.4886	0.9111	0.8402
加入位置嵌入後	0.3930	0.3478	0.4840	0.9113	0.8449

表 4.15 交叉注意力架構導入位置嵌入後之平均分數

觀察表 4.15 的數據可知，在原有的「交叉注意力加上殘差連接」基礎上進一步引入位置嵌入後，模型的 F1-score 由 0.3871 提升至 0.3930，Precision 由 0.3325 提升至 0.3478，AUC 亦由 0.8402 微幅成長至 0.8449。但是，Sensitivity 出現了微幅的下滑，從 0.4886 降至 0.4840，而 Specificity 則幾乎維持平穩(0.9111 至 0.9113)。

此種結果是因為，標準的交叉注意力運算本質上是「無序的 (Permutation-invariant)」，這意味著當 EfficientNet 提取出的局部特徵圖被展平 (Flatten) 並作為查詢向量 (Query) 時，會喪失其在 X 光影像中的原始空間位置資訊。然而，在胸部 X 光影像的臨床診斷中，病理特徵的「絕對位置」往往具有高度的診斷價值。

透過在查詢向量 (Query) 與鍵向量 (Key) 中加入可學習的位置嵌入，模型得以重新獲得空間資訊的引導。這使得模型在進行特徵融合時，不僅比較特徵內容的

相似度，更能考量其空間位置的合理性，使整體的預測品質更加精準，也證實了該元件在架構中的重要性。

4.7 綜合討論

4.7.1 研究結果總結與分析

研究針對 NIH ChestX-ray14 資料集在多標籤胸部 X 光疾病分類上所面臨的挑戰，進行模型架構設計、訓練策略調整與實驗驗證。透過資料上採樣實驗、二階段分類架構分析、長尾分群策略以及特徵融合消融實驗，歸納出以下幾項主要研究發現。

首先，在面對極端類別不平衡與長尾分佈的問題上，實驗結果顯示適度的資料上採樣（將極少數類別上採樣至 1000 筆）結合隨機影像增強，能在綜合評估指標 F1-score 上取得最佳分數。然而，盲目且過度的過採樣（如上採樣至 2000 筆以上）反而會因模型過度學習影像中的特定特徵，而引發過擬合（Overfitting），導致模型效能下降。顯示在醫學影像中，資料上採樣不能單純追求數量上的絕對平衡。

其次，針對資料集長尾分佈問題，本研究設計了二階段十四分類架構與二階段長尾分群架構進行探討。實驗結果顯示，第一階段二分類模型與第二階段 14 分類模型在獨立訓練與評估時，皆能展現一定程度的效能改善。其中，第二階段依據疾病樣本數量差異進行分組訓練，使模型能更專注於疾病特徵學習，進而提升部分少數疾病類別之 Sensitivity。然而，當這些模組串聯為完整的架構之後，前置網路產生的假正例會嚴重讓誤差向下傳遞，使得串聯架構的最終表現不如預期。也凸顯這種分類架構，容易受到前置網路誤判的干擾。

再者，在特徵提取網路的探討中，本研究驗證了卷積神經網路（EfficientNet）與移動視窗自注意力機制（Swin Transformer）在模型效能上的互補性。EfficientNet 憑藉強大的局部特徵歸納偏置（Local Inductive Bias），在大部分的評估指標上具備優勢，而 Swin Transformer 在 Specificity 上表現較為出色。為了結合兩者優勢，本

研究提出之「交叉注意力特徵融合架構」，在經過消融實驗證明，殘差連接(Residual Connection)與位置嵌入(Positional Embedding)的導入，可以較為穩定的在網路中傳遞梯度，模型更可以結合空間資訊去做判斷，使整體架構在 F1-score 與整體辨識能力(AUC)上獲得了小幅提升。

綜上所述，透過一系列實驗比較與分析，本研究歸納出影響胸腔 X 光多標籤分類效能之重要因素。其中，結合適度資料上採樣策略與交叉注意力特徵融合機制之單一網路架構，在各項評估指標中呈現較為穩定之分類表現。

模型名稱	F1-score	Precision	Sensitivity	Specificity	AUC
EfficientNet	0.3820	0.3290	0.4727	0.9124	0.8395
Swin Transformer	0.3627	0.3179	0.4402	0.9193	0.8307
二階段十四分類架構	0.3482	0.3210	0.4189	0.9242	0.7845
二階段長尾分群架構	0.3431	0.3074	0.4258	0.9159	0.7801
交叉注意力特徵融合架構	0.3930	0.3478	0.4840	0.9113	0.8449

表 4.16 5 個模型與架構綜合比較

4.7.2 與現有文獻模型之比較

為進一步驗證本研究所提出模型之分類效能，將交叉注意力特徵融合架構模型與同樣使用 NIH ChestX-ray14 資料集進行訓練與驗證之相關研究進行比較，如表 4.17 所示。由於多數胸腔 X 光疾病分類研究皆以 AUC 作為主要評估指標，因此本研究使用 AUC 作為和其他研究的比較基準。需要注意的是，多數既有研究雖然同樣使用 NIH ChestX-ray14 資料集進行訓練與驗證，但其模型輸出僅包含 14 種疾病標籤，各疾病皆以獨立機率進行預測，並無病徵(No Finding)影像納入模型輸出類別。為確保比較公平性，本研究於比較時，亦將 No Finding 標籤 AUC 分數排除，僅計算與既有研究相同之 14 種疾病類別平均 AUC。

由表 4.17 可觀察，本研究所提出之 EfficientNet 與 Swin Transformer 注意力特

徵融合架構達到 0.8492 的平均 AUC，整體分類效能優於部分基於單一卷積神經網路或 Transformer 架構之研究。例如，CheXNet 透過 DenseNet 架構於 NIH ChestX-ray14 資料集進行肺炎與多疾病分類任務，其 AUC 為 0.8414；SwinCheX 採用 Swin Transformer 作為主要特徵提取架構，其 AUC 為 0.810；而 DCXNet 結合 DenseNet 與遷移學習策略，其 AUC 為 0.8205。本研究透過融合卷積神經網路擅長擷取局部紋理特徵之能力，以及 Swin Transformer 對長距離空間關係建模之優勢，使模型能同時考量局部病灶細節與整體影像結構資訊，因此取得較佳分類表現。

進一步與採用多模型融合策略之研究相比，本研究相較於 SynthEnsemble (AUC=0.8543) 及 DualCheXNet (AUC=0.857) 表現較差一些。SynthEnsemble 透過多種預訓練卷積神經網路與 Transformer 模型組成集成架構，並利用差分演化方法最佳化模型權重；DualCheXNet 則結合 ResNet 與 DenseNet 雙分支架構，透過特徵層級與決策層級融合方式提升分類能力。然而，上述方法皆使用較高運算資源之硬體環境，其中 SynthEnsemble 使用兩張 NVIDIA T4 GPU，共計 32GB 顯示卡記憶體，而 DualCheXNet 則使用四張 TITAN XP GPU，共計 48GB 顯示卡記憶體。相較之下，本研究僅使用單張 NVIDIA RTX 4060 GPU，具備 8GB VRAM，在有限顯示卡記憶體環境下取得 0.8492 的平均 AUC，顯示所提出之模型在分類效能與運算資源需求之間取得良好平衡，不需依賴高容量顯示卡記憶體即可完成模型訓練與推論。

綜合而言，本研究雖未使用高階多 GPU 運算設備，但透過有效的模型融合策略與訓練方式，在具備僅 8GB VRAM 的消費級 GPU 環境下仍取得 0.8492 的平均 AUC，展現深度學習胸腔 X 光疾病分類模型於缺乏高階運算設備之偏鄉地區或醫療資源有限國家中的實際應用潛力，顯示人工智慧輔助診斷系統具備於較低資源環境中部署之可行性。此外，由於本研究採用包含 No Finding 類別之 15 類別分類器，相較僅針對疾病類別進行預測之既有研究，更能反映模型於正常與異常胸腔 X 光影像辨識上的整體分類能力，使評估結果更加完整。

模型與研究文獻	AUC	使用硬體	說明
本研究	0.8492	單張 NVIDIA RTX 4060 8GB VRAM	提出基於 EfficientNet 與 Swin Transformer 的注意力特徵融合架構模型以提升分類效能。
CheXNet (Rajpurkar, et al., 2017)	0.8414	未說明	提出基於 DenseNet 之 CheXNet 模型，並透過與放射科醫師比較肺炎偵測表現，驗證 CNN 於胸腔 X 光疾病分類任務中的應用能力。
SwinCheX (Taslimi, et al., 2022)	0.810	未說明	提出 Swin Transformer 作為骨幹網路並結合多層感知器分類頭，以提升分類效能。
EfficientNet-b7 (Murphy, Venkatesh, Sulam, & Yi, 2022)	0.79	單張 RTX5000 16GB VRAM	比較基於 DeiT、ViT 與多種卷積神經網路架構，並分析不同模型在資料量變化下的準確率，其中胸腔 X 光分類任務中 EfficientNet-b7 為最佳模型。
DCXNet (Karna, Jha,	0.8205	單張 NVIDIA Tesla P100 16GB VRAM	提出基於 DenseNet 與遷移學習之 DCXNet 模

Dahal, Pandey, & Jha, 2023)			型。
SynthEnsemble (Ashraf, et al., 2023)	0.8543	2 張 Nvidia T4 GPU 共計 32GB VRAM	比較多種預訓練 CNN、Transformer 及混合架構模型，並透過差分演化最佳化權重之加權集成方法融合多模型預測結果，以提升分類效能。
DualCheXNet (Chen, Li, et al., 2019)	0.857	4 張 TITAN XP GPU 共計 48GB VRAM 	結合 ResNet 與 DenseNet 之 DualCheXNet 雙分支特徵學習架構，透過特徵層級與決策層級融合策略整合不同卷積神經網路所擷取之互補特徵，以提升分類效能。

表 4.17 與其他現有研究之比較

第五章 結論與未來展望

本研究針對 NIH ChestX-ray14 資料集在多標籤胸腔 X 光疾病分類上所面臨之極端類別不平衡等挑戰，提出並實作了多項模型架構與訓練策略。在處理醫學影像資料不平衡問題上，實驗結果顯示適度的資料上採樣（如將極少數類別擴充至 1000 筆）結合隨機幾何影像增強，能有效為罕見疾病建立決策邊界，並在 F1-score 與 AUC 等評估指標中取得最佳平衡。然而，盲目且過度的上採樣（如擴充至 2000 筆以上）反會因原始特徵多樣性匱乏而引發嚴重的過度擬合（Overfitting），導致整體分類效能下降，此現象也證明了在醫學影像處理中不能單純追求數量上的絕對平衡。

此外，本研究證實傳統的二階段階層式分類架構在複雜醫學影像中存在缺陷。儘管將有無病徵影像分群確實能在獨立的子任務中提升靈敏度（Sensitivity），但當模型被整合時，極易受到誤差向下傳遞之影響。前置網路的假正例誤判會直接破壞後續網路的預測，使得整體系統效能不升反降，凸顯出串聯式架構的劣勢。在單一特徵提取網路的探討中，本研究驗證了卷積神經網路（EfficientNet）與視覺轉換器（Swin Transformer）具備一定的互補性。EfficientNet 憑藉強大的局部歸納偏置（Local Inductive Bias），在捕捉大部分疾病上更為優秀；而 Swin Transformer 則依賴全局感受野與長距離依賴建模能力，在 Specificity 指標上表現更好，證明兩者結合的模型具有一定的潛力提升辨識準確度。

基於上述發現，本研究最終提出之基於 EfficientNet 與 Swin Transformer 之交叉注意力特徵融合架構展現了較好的綜合效能。透過交叉注意力機制（Cross Attention），該架構成功將 CNN 的局部細節與 Transformer 的全局語義進行融合。後續的消融實驗（Ablation Study）也進一步證實，導入殘差連接（Residual Connection）與位置嵌入（Positional Embedding）能夠穩定網路的梯度傳遞，同時保留了病理特徵的空間幾何資訊。最終搭配動態權重學習（Learning Weight）分配三個模型特徵

權重，使融合架構在 F1-score (0.3930) 與 AUC (0.8449) 等核心指標上皆微幅超越了單一網路與二階段架構，展現出較為穩健的多標籤疾病預測能力。

進一步與同樣使用 NIH ChestX-ray14 資料集進行訓練與驗證之相關研究比較後，為確保公平性，以排除 No Finding 類別後之 14 種疾病平均 AUC 作為比較基準。實驗結果顯示，本研究所提出注意力特徵融合架構可達到 0.8492 之平均 AUC，整體分類效能優於 CheXNet、SwinCheX 及 DCXNet 等單一模型架構，雖略低於採用多模型集成之 SynthEnsemble 與 DualCheXNet，但上述研究皆需 32GB 或 48GB 顯示卡記憶體，而本研究僅使用單張具 8GB VRAM 之 NVIDIA RTX 4060 即可完成模型訓練。透過將批次大小設定為 8 並配合梯度累積模擬批次大小 16 之訓練方式，以有效降低顯示卡記憶體需求，在模型分類效能與運算資源需求之間取得良好平衡，證明於有限硬體環境下仍能建立具競爭力之胸腔 X 光疾病分類模型，提升其於偏鄉地區及醫療資源有限國家部署人工智慧輔助診斷系統之可行性。此外，本研究建立包含 No Finding 之 15 類別分類器，相較於既有僅輸出 14 種疾病標籤之研究，更能完整評估模型對正常與異常胸腔 X 光影像之辨識能力，使分類結果更貼近實際臨床篩檢情境。

雖然本研究提出之「交叉注意力特徵融合架構」在胸腔 X 光多標籤分類上提升了部分效能，但面對複雜多變的實際臨床診斷環境，未來仍有數個方向值得進一步深化。

針對現有二階段架構容易產生之限制，未來研究可從三個方向進行改善。首先，在長尾與少數類別學習不足方面，可採用分階段訓練策略，先針對少數類別進行特徵學習，再逐步納入常見類別，以提升模型對長尾分佈中弱勢類別的辨識能力。其次，在改善二階段誤差傳遞問題上，第一階段不再採用硬性決策輸出，而是改為輸出病徵機率分佈，作為輔助特徵與原始影像特徵共同輸入第二階段，使模型能保留不確定性資訊並進行更穩健的疾病判斷，以降低早期誤判所造成的資訊損失。最後，在臨床應用層面，可進一步導入多模態臨床資訊 (Multi-modal Learning)，結合醫

學影像與病患年齡、性別、病史及電子病歷（EHR）等資料，透過特徵融合或注意力機制進行跨模態整合，以提升整體臨床輔助診斷之準確性與可靠性。



參考文獻

- Ashari RakhmatGalih, & Muhammad YudiantiraAditya. (2024). Implementation and Optimization Of Inception Resnet-v2 with Data Balancing (Case Study Of Lung Disease Classification). E3S Web of Conferences, 02010.
- AshrafN.S., MamunA.M., AbdullahM.H., & AlamG. R.M. (2023). SynthEnsemble: A fusion of CNN, vision transformer, and Hybrid models for multi-label chest X-ray classification. 2023 26th International Conference on Computer and Information Technology (ICCIT) — IEEE, 1 – 6.
- BahdanauD., ChoK., & BengioY. (2014). Neural machine translation by jointly learning to align and translate. *arXiv*.
- BudaM., MakiA., & MazurowskiA.M. (2018). A systematic study of the class imbalance problem in convolutional neural networks. *Neural Networks*, 249-259.
- Chamseddine, E., Mansouri, N., Soui, M., & Abed, M. (2022). Handling Class Imbalance in COVID-19 Chest X-ray Images Classification: Using SMOTE and Weighted Loss. *Applied Soft Computing*, 109588.
- Chen, C. F., Fan, Q., & Panda, R. (2021). Crossvit: Cross-attention multi-scale vision transformer for image classification. *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 357-366.
- ChenB., LiJ., GuoX., & LuG. (2019). DualCheXNet: Dual Asymmetric Feature Learning for Thoracic Disease Classification in Chest X-Rays. *Biomedical Signal Processing and Control*, 101554.
- Chlap, P., Min, H., Vandenberg, N., Dowling, J., Holloway, L., & Haworth, A. (2021). A review of medical image data augmentation techniques for deep learning applications. *Journal of Medical Imaging and Radiation Oncology*, 545-563.
- DaiZ., LiuH., LeV.Q., & TanM. (2021). Coatnet: Marrying convolution and attention for all data sizes. *Advances in Neural Information Processing Systems*, 3965-3977.
- Deng, J., Dong, W., Socher, R., Li, L. J., Li, K., & Fei-Fei, L. (2009). Imagenet: A large-scale hierarchical image database. *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 248-255.
- DietterichG.T. (2000). Ensemble Methods in Machine Learning. Multiple Classifier Systems (Lecture Notes in Computer Science) , 1-15.
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., & Houlsby, T. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint*.

- Goodfellow I., Bengio Y., & Courville A. (2016). Deep learning. MIT Press, 1-800.
- Huang L., Ma J., Yang H., & Wang Y. (2024). Research and Implementation of Multi-disease Diagnosis on Chest X-ray Based on Vision Transformer. *Quantitative Imaging in Medicine and Surgery*, 2539-2555.
- Jalalifar, S. A., & Sadeghi-Naini, A. (2022). Data-efficient Training of Pure Vision Transformers for the Task of Chest X-ray Abnormality Detection Using Knowledge Distillation. *2022 44th Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)*, 1444-1447.
- Karna, A., Jha, A., Dahal, A., Pandey, A., & Jha, T. (2023). Chest X-ray Classification Using DenseNet. *Proc 13th IOE Graduate Conference*.
- Krizhevsky A., Sutskever I., & Hinton E.G. (2012). Imagenet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25.
- LeCun Y., Bengio Y., & Hinton G. (2015). Deep learning. *Nature*, 436-444.
- Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A., Ciompi, F., Ghafoorian, M., & Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical image analysis*, 60-88.
- Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., & Guo, B. (2021). Swin transformer: Hierarchical vision transformer using shifted windows. *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 10012-10022.
- Liu, Z., Miao, Z., Zhan, X., Wang, J., Gong, B., & Yu, S. X. (2019). Large-scale long-tailed recognition in an open world. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2537-2546.
- Marques G., Agarwal D., & De la Torre D. (2020). Automated medical diagnosis of COVID-19 through EfficientNet convolutional neural network. *Applied Soft Computing*, 106691.
- Murphy R.Z., Venkatesh K., Sulam J., & Yi H.P. (2022). Visual Transformers and Convolutional Neural Networks for Disease Classification on Radiographs: A Comparison of Performance, Sample Efficiency, and Hidden Stratification. *Radiology: Artificial Intelligence*, e220012.
- Pan J.S., & Yang Q. (2009). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 1345-1359.
- Rajpurkar, P., Irvin, J., Zhu, K., Yang, B., Mehta, H., Duan, T., & Ng, A. Y. (2017). CheXNet: Radiologist-Level Pneumonia Detection on Chest X-rays with Deep Learning. *arXiv preprint*.
- Schautd, D., Späte, C., von Schwerin, R., Reichert, M., von Schwerin, M., & Beer, M.

- C. (2023). A Critical Assessment of Generative Models for Synthetic Data Augmentation on Limited Pneumonia X-ray Data. *Bioengineering*, 1421.
- Schlemper, J., Oktay, O., Schaap, M., Heinrich, M., Kainz, B., Glocker, B., & Rueckert, D. (2019). Attention gated networks: Learning to leverage salient regions in medical images. *Medical Image Analysis*, 197-207.
- ShortenC., & KhoshgoftaarM.T. (2019). A survey on image data augmentation for deep learning. *Journal of Big Data*, 1-48.
- SundaramS., & HulkundN. (2021). GAN-based Data Augmentation for Chest X-ray Classification. *arXiv*.
- Tajbakhsh, N., Shin, J. Y., Gurudu, S. R., Hurst, R. T., Kendall, C. B., Gotway, M. B., & Liang, J. (2016). Convolutional neural networks for medical image analysis: Full training or fine tuning? *IEEE Transactions on Medical Imaging*, 1299-1312.
- TanM., & LeQ. (2019). Efficientnet: Rethinking model scaling for convolutional neural networks. *International Conference on Machine Learning*, 6105-6114.
- Taslimi, S., Taslimi, S., Fathi, N., Salehi, M., & Rohban, M. H. (2022). SwinCheX: Multi-label classification on chest X-ray images with transformers. *arXiv*.
- Touvron, H., Cord, M., Douze, M., Massa, F., Sablayrolles, A., & Jégou, H. (2021). Training Data-efficient Image Transformers & Distillation Through Attention. *Proceedings of the 38th International Conference on Machine Learning*, 10347-10357.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.
- Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M., & Summers, R. M. (2017). Chestx-ray8: Hospital-scale chest x-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2097-2106.
- XiangL., DingG., & HanJ. (2020). Learning from multiple experts: Self-paced knowledge distillation for long-tailed classification. *European Conference on Computer Vision*, 247-263.
- ZophB., & LeV.Q. (2016). Neural architecture search with reinforcement learning. *arXiv preprint*, 1611.01578.

附錄

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.4083	0.3488	0.4923	0.8946	0.8149
HEA	0.3818	0.3962	0.3684	0.9986	0.9336
CAY	0.3549	0.2936	0.4486	0.9718	0.9055
INN	0.4177	0.3177	0.6097	0.7120	0.7168
CON	0.2318	0.1620	0.4072	0.9058	0.8031
MAS	0.3756	0.3061	0.4858	0.9367	0.8376
EDA	0.2987	0.2377	0.4019	0.9694	0.8993
NOE	0.3427	0.3192	0.3700	0.9526	0.7846
EFN	0.5445	0.4844	0.6217	0.9069	0.8779
PLG	0.2140	0.1652	0.3035	0.9570	0.8093
EMA	0.5070	0.4795	0.5378	0.9843	0.9290
PNA	0.1062	0.0626	0.3487	0.9309	0.7701
FIS	0.1985	0.2070	0.1906	0.9891	0.8142
PNX	0.4492	0.3673	0.5781	0.9482	0.8940
NOG	0.7454	0.6658	0.8468	0.5200	0.7759
平均	0.3718	0.3209	0.4674	0.9052	0.8377

附錄 1 未經過資料增強 EfficientNet 各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.4071	0.3179	0.5662	0.8607	0.8178
HEA	0.4400	0.5116	0.3860	0.9991	0.9312
CAY	0.3561	0.3039	0.4300	0.9743	0.8915
INN	0.4091	0.3188	0.5706	0.7318	0.7160
CON	0.2354	0.1595	0.4493	0.8941	0.8059
MAS	0.4124	0.4344	0.3926	0.9706	0.8631
EDA	0.3039	0.2423	0.4074	0.9698	0.8946
NOE	0.3497	0.3347	0.3662	0.9563	0.8004
EFN	0.5461	0.4798	0.6336	0.9034	0.8831
PLG	0.2215	0.1801	0.2877	0.9632	0.8072
EMA	0.5171	0.4571	0.5954	0.9810	0.9355
PNA	0.1083	0.0674	0.2763	0.9494	0.7845
FIS	0.2048	0.1989	0.2111	0.9874	0.8029
PNX	0.4321	0.3494	0.5660	0.9452	0.8923
NOG	0.7467	0.6946	0.8072	0.5993	0.7817
平均	0.3794	0.3367	0.4630	0.9124	0.8405

附錄 2 經過資料增強 EfficientNet 各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.4171	0.3404	0.5386	0.8803	0.8158
HEA	0.4754	0.4462	0.5088	0.9985	0.9379
CAY	0.3783	0.3501	0.4115	0.9800	0.9108
INN	0.4154	0.3197	0.5930	0.7224	0.7194
CON	0.2310	0.1749	0.3400	0.9283	0.8064
MAS	0.4088	0.3509	0.4897	0.9479	0.8492
EDA	0.2794	0.1997	0.4648	0.9558	0.8970
NOE	0.3555	0.3511	0.3601	0.9600	0.7936
EFN	0.5444	0.4823	0.6249	0.9057	0.8798
PLG	0.2177	0.1693	0.3050	0.9580	0.8026
EMA	0.5134	0.4333	0.6299	0.9779	0.9329
PNA	0.1028	0.0643	0.2566	0.9506	0.7635
FIS	0.1846	0.1534	0.2317	0.9810	0.8101
PNX	0.4538	0.4102	0.5078	0.9620	0.8908
NOG	0.7521	0.6890	0.8280	0.5780	0.7833
平均	0.3820	0.3290	0.4727	0.9124	0.8395

附錄 3 上採樣至最少 1000 筆 EfficientNet 各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.3997	0.3396	0.4856	0.8917	0.8112
HEA	0.2876	0.2292	0.3860	0.9968	0.9410
CAY	0.3397	0.3372	0.3423	0.9824	0.8849
INN	0.4114	0.3391	0.5227	0.7759	0.7070
CON	0.2274	0.1631	0.3751	0.9139	0.7996
MAS	0.4121	0.4050	0.4194	0.9646	0.8437
EDA	0.2845	0.2088	0.4463	0.9599	0.8952
NOE	0.3466	0.3070	0.3980	0.9461	0.7895
EFN	0.5476	0.5038	0.5998	0.9169	0.8771
PLG	0.2095	0.1459	0.3711	0.9390	0.7934
EMA	0.5104	0.4313	0.6250	0.9779	0.9137
PNA	0.0984	0.0631	0.2237	0.9561	0.7714
FIS	0.1580	0.1199	0.2317	0.9747	0.8067
PNX	0.4304	0.3702	0.5139	0.9545	0.8886
NOG	0.7492	0.7044	0.8001	0.6210	0.7800
平均	0.3608	0.3112	0.4494	0.9181	0.8335

附錄 4 上採樣至最少 2000 筆 EfficientNet 各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.3871	0.3031	0.5357	0.8588	0.8016
HEA	0.3259	0.2821	0.3860	0.9976	0.9456
CAY	0.3505	0.3082	0.4064	0.9762	0.8921
INN	0.4084	0.3357	0.5213	0.7731	0.7035
CON	0.2231	0.1437	0.4985	0.8672	0.8006
MAS	0.3889	0.3479	0.4408	0.9525	0.8446
EDA	0.2743	0.1862	0.5204	0.9460	0.8901
NOE	0.3328	0.3383	0.3275	0.9615	0.7851
EFN	0.5307	0.4735	0.6036	0.9056	0.8745
PLG	0.1976	0.1306	0.4057	0.9242	0.7964
EMA	0.5229	0.5030	0.5444	0.9856	0.9187
PNA	0.1038	0.0700	0.2007	0.9648	0.7711
FIS	0.1684	0.1401	0.2111	0.9807	0.7930
PNX	0.4251	0.3513	0.5382	0.9483	0.8815
NOG	0.7479	0.7093	0.7908	0.6341	0.7781
平均	0.3592	0.3082	0.4621	0.9117	0.8318

附錄 5 上採樣至最少 3000 筆 EfficientNet 各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.3894	0.3444	0.4480	0.9022	0.8012
HEA	0.3407	0.2949	0.4035	0.9976	0.9112
CAY	0.3478	0.3050	0.4047	0.9759	0.8942
INN	0.4136	0.3424	0.5223	0.7793	0.7093
CON	0.2166	0.1369	0.5196	0.8534	0.7989
MAS	0.3748	0.3802	0.3697	0.9654	0.8469
EDA	0.2867	0.2088	0.4574	0.9589	0.8917
NOE	0.3244	0.3105	0.3397	0.9547	0.7851
EFN	0.5371	0.4609	0.6433	0.8942	0.8741
PLG	0.1871	0.1382	0.2893	0.9494	0.7670
EMA	0.5441	0.5021	0.5938	0.9842	0.9203
PNA	0.0972	0.0629	0.2138	0.9578	0.7670
FIS	0.1670	0.1187	0.2815	0.9689	0.7923
PNX	0.4202	0.3628	0.4991	0.9544	0.8799
NOG	0.7470	0.6900	0.8142	0.5870	0.7766
平均	0.3596	0.3106	0.4533	0.9122	0.8277

附錄 6 上採樣至最少 4000 筆 EfficientNet 各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.4027	0.3398	0.4939	0.8900	0.8113
HEA	0.3673	0.3000	0.4737	0.9973	0.9179
CAY	0.3387	0.3246	0.3541	0.9807	0.9011
INN	0.4164	0.3682	0.4789	0.8193	0.7116
CON	0.2268	0.1590	0.3952	0.9065	0.8075
MAS	0.3963	0.3713	0.4250	0.9586	0.8433
EDA	0.2883	0.2156	0.4352	0.9624	0.8984
NOE	0.3114	0.2858	0.3419	0.9487	0.7639
EFN	0.5456	0.4840	0.6252	0.9063	0.8799
PLG	0.2181	0.1614	0.3365	0.9509	0.8002
EMA	0.4933	0.4763	0.5115	0.9849	0.9219
PNA	0.0954	0.0604	0.2270	0.9533	0.7625
FIS	0.1682	0.1757	0.1613	0.9888	0.7890
PNX	0.4234	0.3530	0.5286	0.9496	0.8739
NOG	0.7488	0.6930	0.8145	0.5926	0.7788
平均	0.3627	0.3179	0.4402	0.9193	0.8307

附錄 7 上採樣至最少 1000 筆 SwinTransformer 各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.5334	0.4494	0.6559	0.7747	0.7871
HEA	0.5102	0.6098	0.4386	0.9985	0.9447
CAY	0.5290	0.5127	0.5464	0.9702	0.9119
INN	0.6080	0.5020	0.7707	0.5237	0.7061
CON	0.2892	0.1929	0.5777	0.7576	0.7180
MAS	0.5038	0.4813	0.5284	0.9255	0.8280
EDA	0.3690	0.2859	0.5204	0.9325	0.8654
NOE	0.4407	0.3941	0.4996	0.8947	0.7922
EFN	0.6115	0.5577	0.6768	0.8090	0.8248
PLG	0.2780	0.2217	0.3726	0.9192	0.7748
EMA	0.5886	0.5358	0.6530	0.9667	0.9331
PNA	0.1318	0.0891	0.2533	0.9260	0.7086
FIS	0.2675	0.2401	0.3021	0.9692	0.8216
PNX	0.5359	0.4554	0.6510	0.9083	0.8750
平均	0.4426	0.3948	0.5319	0.8768	0.8208

附錄 8 14 分類模型各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
HEA	0.6316	0.7895	0.5263	0.9987	0.9525
CAY	0.6471	0.6862	0.6121	0.9706	0.9244
CON	0.4453	0.3756	0.5466	0.8269	0.7669
MAS	0.5537	0.4857	0.6438	0.8261	0.8106
EDA	0.5050	0.4955	0.5148	0.9503	0.8835
NOE	0.5173	0.4358	0.6361	0.7789	0.7751
PLG	0.3573	0.2999	0.4418	0.8827	0.7580
EMA	0.6473	0.6750	0.6217	0.9676	0.9256
PNA	0.1842	0.1126	0.5066	0.7951	0.7165
FIS	0.2764	0.2342	0.3372	0.9362	0.8038
PNX	0.6326	0.5576	0.7309	0.8685	0.8726
平均	0.4907	0.4680	0.5562	0.8910	0.8354

附錄 9 11 分類尾部模型各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.6048	0.5151	0.7324	0.6782	0.7811
INN	0.7503	0.6630	0.8643	0.4453	0.7591
EFN	0.7063	0.6122	0.8346	0.6738	0.8390
平均	0.6871	0.5967	0.8104	0.5991	0.7931

附錄 10 3 分類頭部模型各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.389	0.321	0.4935	0.8803	0.7762
HEA	0.4348	0.5714	0.3509	0.9994	0.8485
CAY	0.2964	0.2911	0.3019	0.9808	0.7311
INN	0.3887	0.2989	0.5558	0.7132	0.6656
CON	0.2027	0.1366	0.3932	0.8888	0.7619
MAS	0.3925	0.3558	0.4376	0.9545	0.8171
EDA	0.26	0.1922	0.4019	0.9599	0.8626
NOE	0.3208	0.2805	0.3745	0.9423	0.7382
EFN	0.5214	0.4443	0.6308	0.8891	0.8611
PLG	0.1929	0.1541	0.2579	0.9603	0.7472
EMA	0.4657	0.3998	0.5576	0.9776	0.8615
PNA	0.0946	0.0591	0.2368	0.9501	0.7469
FIS	0.1998	0.1642	0.2551	0.9807	0.7293
PNX	0.4067	0.3567	0.4731	0.9556	0.8471
NOG	0.6567	0.7893	0.5622	0.8306	0.7725
平均	0.3482	0.3210	0.4189	0.9242	0.7845

附錄 11 二階段 14 分類各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.3773	0.3063	0.491	0.8725	0.7729
HEA	0.4444	0.4058	0.4912	0.9982	0.8482
CAY	0.2969	0.2672	0.3339	0.9761	0.7325
INN	0.3721	0.2621	0.6413	0.6028	0.6506
CON	0.2143	0.1509	0.3691	0.9071	0.7781
MAS	0.3696	0.3455	0.3973	0.9567	0.8121
EDA	0.2874	0.2371	0.3648	0.9721	0.8639
NOE	0.2865	0.2657	0.3108	0.9484	0.7226
EFN	0.5227	0.4686	0.5907	0.9058	0.8617
PLG	0.1828	0.1364	0.2767	0.9508	0.7354
EMA	0.4942	0.4447	0.5559	0.9814	0.8593
PNA	0.0696	0.0393	0.3026	0.9022	0.7173
FIS	0.1391	0.1375	0.1408	0.9869	0.713
PNX	0.4336	0.3545	0.5582	0.9471	0.8616
NOG	0.6567	0.7893	0.5622	0.8306	0.7725
平均	0.3431	0.3074	0.4258	0.9159	0.7801

附錄 12 二階段結合長尾模型各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.4174	0.3456	0.5269	0.8856	0.8140
HEA	0.5085	0.4918	0.5263	0.9987	0.8838
CAY	0.3651	0.3396	0.3946	0.9800	0.8938
INN	0.4123	0.3336	0.5397	0.7629	0.7128
CON	0.2179	0.1387	0.5075	0.8590	0.7980
MAS	0.4170	0.3640	0.4882	0.9510	0.8598
EDA	0.2953	0.2153	0.4704	0.9593	0.8907
NOE	0.3311	0.3308	0.3313	0.9598	0.7783
EFN	0.5427	0.4657	0.6503	0.8951	0.8774
PLG	0.2044	0.1496	0.3223	0.9486	0.7790
EMA	0.5281	0.4655	0.6102	0.9812	0.9116
PNA	0.0979	0.0603	0.2599	0.9464	0.7548
FIS	0.1555	0.1432	0.1701	0.9849	0.7791
PNX	0.4311	0.3533	0.5530	0.9473	0.8857
NOG	0.7472	0.6884	0.8169	0.5826	0.7813
平均	0.3781	0.3257	0.4778	0.9095	0.8267

附錄 13 Cross Attention 模型各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.4188	0.3447	0.5336	0.8837	0.8216
HEA	0.4662	0.4079	0.5439	0.9981	0.8702
CAY	0.3738	0.2969	0.5042	0.9688	0.9190
INN	0.4198	0.3382	0.5532	0.7619	0.7236
CON	0.2386	0.1910	0.3180	0.9397	0.8076
MAS	0.4276	0.3671	0.5118	0.9493	0.8671
EDA	0.3024	0.2345	0.4259	0.9670	0.8999
NOE	0.3408	0.3198	0.3647	0.9534	0.7977
EFN	0.5532	0.5254	0.5841	0.9258	0.8825
PLG	0.2334	0.1657	0.3947	0.9442	0.8160
EMA	0.5374	0.4886	0.5970	0.9832	0.9435
PNA	0.0989	0.0567	0.3849	0.9154	0.7699
FIS	0.1930	0.2096	0.1789	0.9900	0.8012
PNX	0.4497	0.3663	0.5825	0.9475	0.8943
NOG	0.7535	0.6755	0.8520	0.5379	0.7883
平均	0.3871	0.3325	0.4886	0.9111	0.8402

附錄 14 Cross Attention 加上 Residual Connection 模型各標籤分數

	F1-score	Precision	Sensitivity	Specificity	AUC
ATS	0.4270	0.3381	0.5791	0.8700	0.8240
HEA	0.5106	0.6486	0.4211	0.9994	0.9311
CAY	0.3854	0.3503	0.4283	0.9792	0.9160
INN	0.4226	0.3370	0.5663	0.7549	0.7234
CON	0.2496	0.1865	0.3771	0.9264	0.8094
MAS	0.4235	0.3585	0.5174	0.9468	0.8710
EDA	0.3103	0.2520	0.4037	0.9716	0.9042
NOE	0.3546	0.3065	0.4208	0.9428	0.8003
EFN	0.5561	0.4756	0.6695	0.8962	0.8851
PLG	0.2241	0.1562	0.3962	0.9399	0.8091
EMA	0.5358	0.4816	0.6036	0.9826	0.9425
PNA	0.0978	0.0582	0.3059	0.9346	0.7676
FIS	0.2020	0.2018	0.2023	0.9881	0.8152
PNX	0.4443	0.3749	0.5451	0.9527	0.8899
NOG	0.7512	0.6911	0.8227	0.5848	0.7841
平均	0.3930	0.3478	0.4840	0.9113	0.8449

附錄 15 完整 Cross Attention 特徵融合架構各標籤分數